

III.5. Test o proporciji/vjerojatnosti događaja (binomni test)

Zadatak 1. U 10 nezavisnih bacanja novčića 7 puta okrenulo se pismo. Možemo li na razini značajnosti 0.1 tvrditi da novčić nije pravilan?

```
##### Zadatak 1.
#theta – vjerojatnost pisma
#Hipoteze:
# H0: theta = 1/2
# H1: theta != 1/2
binom.test(7, 10, p = 0.5, alternative = "two.sided")
#p = 0.3438 > 0.1 – Na razini značajnosti 0.1 ne odbacujemo H0,
#tj. na razini značajnosti 0.1 ne možemo tvrditi da novčić nije pravilan.
```

Zadatak 2. Kockar sudjeluje u igri na sreću u kojoj baca svoj novčić i dobiva ako se okrene glava. Kockarnica prije njegovog pristupanja igri želi provjeriti je li novčić pristran, u smislu da se pri bacanju novčića glava realizira s vjerojatnošću većom od 1/2. U tu svrhu kontrolor je izveo 1000 nezavisnih bacanja kockarevog novčića i utvrdio da se 555 puta okrenula glava. Možemo li na razini značajnosti 0.05 tvrditi da kockar želi dobiti igru na prijevaru?

```
##### Zadatak 2.
#theta – vjerojatnost glave
#Hipoteze:
# H0: theta = 1/2 (kockar je nevin)
# H1: theta > 1/2 (kockar pokušava varati)
binom.test(555, 1000, p = 0.5, alternative = "greater")
# p = 0.00028 < 0.05 – Na razini značajnosti 0.05 odbacujemo H0 i
    prihvaćamo H1,
#tj. na razini značajnosti 0.05 možemo tvrditi da je novčić pristran
#i da kockar želi dobiti igru na prijevaru.
```

Zadatak 3. Milan tvrdi da je vidovit. Želimo to provjeriti pa ga testiramo na sljedeći način: iz špila od 52 karte (13 hercova, 13 pikova, 13 trefova i 13 karo karata) jednu po jednu s vraćanjem u špil izvlačimo 25 karata. Po izvlačenju svake karte pitamo ga da pogodi boju karte i bilježimo njegove odgovore. Pretpostavimo da je pogodio boje 12 izvučenih karata. Je li to dovoljan dokaz da na razini značajnosti $\alpha = 0.05$ možemo tvrditi da je Milan zaista vidovit?

```
##### Zadatak 3.
#theta – vjerojatnost da Milan pogodi boju
#Hipoteze:
# H0: \theta = 1/4 (Milan nije vidovit, slučajno pogađa)
# H1: \theta > 1/4 (Milan je vidovit)
binom.test(12, 25, p = 0.25, alternative = "greater")
#p = 0.01073 < 0.05 – Na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
H1,
#tj. na razini značajnosti 0.05 možemo tvrditi da je Milan vidovit.
```

Zadatak 4. Varijabla *CLOtest* u tablici podataka *hormon.csv* za svakog ispitanika iz uzorka sadrži rezultate testa na *helicobacter pylori* (0 - negativan rezultat testa, 1 - pozitivan rezultat testa). Možemo li na razini značajnosti 0.05 tvrditi da je proporcija ljudi u promatranoj populaciji s negativnim rezultatom testa statistički značajno manja od 20%?

```
##### Zadatak 4.
# theta – nepoznata proporcija ljudi s negativnim rezultatom
#Hipoteze:
# H0: theta = 0.2
# H1: theta < 0.2
hormon <- read.csv2("hormon.csv")
str(hormon)
clo <- hormon$CLOtest
table(clo)
length(clo)
binom.test(12, 82, p = 0.2, alternative = "less")
#p=0.1394 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0, tj. ne
možemo tvrditi da je proporcija
#ljudi u promatranoj populaciji s negativnim rezultatom testa statistički
značajno manja od 20%.
```

III.6. Test o kvantilima

Zadatak 5. U stupcu *weight* R tablice podataka *ChickWeight* nalaze se podaci o masi pilića u gramima. Testirajte je li medijan mase pilića veći od 100 grama na razini značajnosti 0.05.

```
##### Zadatak 5.
str(ChickWeight)
x <- ChickWeight$weight
median(x)
#Hipoteze:
# H0: medijan = 100
# H1: medijan > 100
#<=>
# H0: Q(0.5) = 100
# H1: Q(0.5) > 100
#Q – funkcija kvantila populacijske distribucije mase pilića
#<=>
# H0: F(100) = 0.5
# H1: F(100) < 0.5
#<=>
# H0: P(X <= 100) = 0.5
# H1: P(X <= 100) < 0.5
#X – slučajna varijabla koja modelira masu pilića u populaciji
#Označimo theta = P(X <= 100)
#<=>
# H0: theta = 0.5
# H1: theta < 0.5
#Sveli smo na problem procjene vjerojatnosti događaja.
#Uzorak iz Bernoullijeve distribucije:
x <= 100
#Broj uspjeha:
table(x <= 100) #ili sum(x <= 100)
#Broj ponavljanja:
length(x)
binom.test(278, 578, p = 0.5, alternative = "less")
#p=0.1912 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0, tj. ne
možemo tvrditi da je medijan mase
#pilića statistički značajno veći od 100.
```

Zadatak 6. Pretpostavimo da je zaključak nekog medicinskog istraživanja da je koncentracija hormona gastrina u serumu manja ili jednaka od 51 (mMol/l) kod točno 50% ljudi u populaciji. Možemo li na temelju mjerenja koncentracije gastrina u serumu sadržanih u tablici podataka *hormon.csv* na razini značajnosti 0.05 opovrgnuti rezultate tog istraživanja?

```
##### Zadatak 6.
hormon <- read.csv2("hormon.csv")
str(hormon)
x <- na.omit(hormon$gastrS)
median(x)
#Prethodno istraživanje: medijan koncentracije je 51
#Hipoteze:
# H0: medijan = 51      Q(0.5) = 51
# H1: medijan != 51     Q(0.5) != 51
#<=>
# H0: F(51) = 0.5
# H1: F(51) != 0.5
#<=>
# H0: \theta = 0.5
# H1: \theta != 0.5
#gdje je \theta = P(X <= 51) = F(51).
table(x<=51)
length(x)
binom.test(50, 78, p = 0.5, alternative = "two.sided")
#p = 0.01685 < 0.05 – Na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
H1,
#tj. na razini značajnosti 0.05 možemo tvrditi da smo opovrgnuli rezultate
prethodnog medicinskog istraživanja.
#Medijan je različit od 51.
```

Zadatak 7. Varijabla *visina_kredita* tablice podataka *kredit_i.csv* sadrži iznose kredita za 146 poduzeća. Možemo li tvrditi na razini značajnosti 0.05 da je 0.9-kvantil distribucije visine dodijeljenih kredita manji od 110000?

```
##### Zadatak 7.
kredit_i <- read.csv2("kredit_i.csv")
str(kredit_i)
vis <- kredit_i$visina_kredita
#Q(0.9) je nepoznati 0.9-kvantil. Procjena tog kvantila je
quantile(vis, 0.9)
#Hipoteze:
# H0: Q(0.9) = 110000
# H1: Q(0.9) < 110000
#<=>
# H0: F(110000) = 0.9
# H1: F(110000) > 0.9
#<=>
# H0: \theta = 0.9
# H1: \theta > 0.9
#gdje je \theta = P(X <= 110000) = F(110000).
table(vis <= 110000)
length(vis)
binom.test(137, 146, p = 0.9, alternative = "greater")
#p = 0.07312 > 0.05 – Na razini značajnosti 0.05 ne odbacujemo H0,
```

#tj. ne možemo tvrditi da je 0.9–kvantil distribucije visine kredita manji od 110000 kn