

III.5. Test o proporciji/vjerojatnosti događaja (binomni test)

Sadržaj

1. Dvostrani test	1
2. Jednostrani testovi	2

Neka je $\mathbf{X} = (X_1, \dots, X_n)$ j.s.u. iz Bernoullijeve distribucije

$$\begin{pmatrix} 0 & 1 \\ 1 - \theta & \theta \end{pmatrix}, \quad \theta \in (0, 1).$$

Nepoznati parametar θ intepretiramo kao proporciju (udio) u cijeloj populaciji ili kao vjerojatnost nekog događaja. Želimo testirati je li θ jednak nekoj unaprijed zadanoj vrijednosti θ_0 na razini značajnosti α

$$H_0 : \theta = \theta_0.$$

Test statistika će biti broj uspjeha (jedinica) u uzorku

$$T = T(\mathbf{X}) = \sum_{i=1}^n X_i$$

i ima binomnu distribuciju od čega dolazi i naziv testa – **binomni test**. Ako je H_0 istinita, onda $T \sim \mathcal{B}(n, \theta_0)$. Treba napomenuti da je ovo **egzaktan test** jer je distribucija test statistike poznata bez obzira o koliko malo uzorku se radi za razliku od asimptotskih testova.

1. Dvostrani test

Za hipoteze

$$H_0 : \theta = \theta_0,$$

$$H_1 : \theta \neq \theta_0,$$

kritično područje je

$$C = \{0, \dots, \underline{k}\} \cup \{\bar{k}, \dots, n\},$$

gdje je $\underline{k}$ najveći element od $\{0, 1, \dots, n\}$ takav da je

$$P_{\theta_0}(T \leq \underline{k}) = \sum_{k=0}^{\underline{k}} \binom{n}{k} \theta_0^k (1 - \theta_0)^{n-k} \leq \frac{\alpha}{2},$$

a $\bar{k}$ je najmanji element od $\{0, 1, \dots, n\}$ takav da je

$$P_{\theta_0}(T \geq \bar{k}) = \sum_{k=0}^{\bar{k}} \binom{n}{k} \theta_0^k (1 - \theta_0)^{n-k} \leq \frac{\alpha}{2}.$$

Naizgled komplicirane formule treba gledati kao određivanje kritičnog područja kod z -testa ili t -testa. Za razliku od tih testova, distribucija test statistike je ovdje diskretna.

Neka je $\hat{t}$ realizacija test statistike. Tada je p -vrijednost

$$p = \sum_{\{k \in \{0, 1, \dots, n\} : P_{\theta_0}(T=k) \leq P_{\theta_0}(T=\hat{t})\}} P_{\theta_0}(T = k),$$

odnosno, p -vrijednost je vjerojatnost da T bude jednaka ili ekstremnija od $\hat{t}$ (jednako ili manje vjerojatna).

2. Jednostrani testovi

Za hipoteze

$$\begin{aligned} H_0 : \theta &= \theta_0, \\ H_1 : \theta &> \theta_0, \end{aligned}$$

kritično područje je

$$C = \{k_1, \dots, n\},$$

gdje je k_1 najmanji element od $\{0, 1, \dots, n\}$ takav da je

$$P_{\theta_0}(T \geq k_1) = \sum_{k=k_1}^n \binom{n}{k} \theta_0^k (1 - \theta_0)^{n-k} \leq \alpha,$$

a p -vrijednost je

$$p = P_{\theta_0}(T \geq \hat{t}).$$

Za hipoteze

$$\begin{aligned} H_0 : \theta &= \theta_0, \\ H_1 : \theta &< \theta_0, \end{aligned}$$

kritično područje je

$$C = \{0, 1, \dots, k_2\},$$

gdje je k_2 najveći element od $\{0, 1, \dots, n\}$ takav da je

$$P_{\theta_0}(T \leq k_2) = \sum_{k=0}^{k_2} \binom{n}{k} \theta_0^k (1 - \theta_0)^{n-k} \leq \alpha,$$

a p -vrijednost je

$$p = P_{\theta_0}(T \leq \hat{t}).$$

Primjer 1. U 10 nezavisnih bacanja novčića 7 puta se okrenulo pismo. Možemo li na razini značajnosti 0.1 tvrditi da novčić nije pravilan?

Radi se o uzorku $\mathbf{X} = (X_1, \dots, X_{10})$ iz Bernoullijeve distribucije

$$\begin{pmatrix} 0 & 1 \\ 1 - \theta & \theta \end{pmatrix}, \quad \theta \in (0, 1),$$

gdje 1 označava, primjerice, pismo, a θ je vjerojatnost da padne pismo. Želimo testirati

$$\begin{aligned} H_0 : \theta &= \frac{1}{2} && \text{novčić je pravilan,} \\ H_1 : \theta &\neq \frac{1}{2} && \text{novčić nije pravilan.} \end{aligned}$$

Ako vrijedi H_0 , onda test statistika T ima distribuciju $T \sim \mathcal{B}(10, 0.5)$, što možemo prikazati tablicom (izračunamo u R s `dbinom(0:10, 10, 0.5)`)

$$T \sim \begin{pmatrix} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 \\ 0.00098 & 0.00977 & 0.04395 & 0.11719 & 0.20508 & 0.24609 & 0.20508 & 0.11719 & 0.04395 & 0.00977 & 0.00098 \end{pmatrix}.$$

Za kritično područje tražimo najveći $\underline{k}$ i najmanji $\bar{k}$ takav da je

$$P(T \leq \underline{k}) \leq \frac{\alpha}{2} = 0.05, P(T \geq \bar{k}) \leq \frac{\alpha}{2} = 0.05.$$

Slijedi da je

$$C = \{0, 1\} \cup \{9, 10\}.$$

Realizacija test statistike je $\hat{t} = 7$ (broj uspjeha – pisama). Kako $\hat{t} \notin C$, ne odbacujemo H_0 na razini značajnosti 0.1 – ne možemo tvrditi da novčić nije pravilan.

Drugi način kako možemo doći do zaključka je pomoću p -vrijednosti. Kako je $P(T = \hat{t}) = 0.11719$, vjerojatnost svih ishoda manje ili jednako vjerojatnih od $\hat{t}$ je

$$p = P(T \in \{0, 1, 2, 3, 7, 8, 9, 10\}) = 0.34375 > 0.1.$$

III.6. Test o kvantilima

Neka je $\mathbf{X} = (X_1, \dots, X_n)$ j.s.u. iz funkcije distribucije F slučajne varijable X s funkcijom kvantila Q . Sjetimo se da je funkcija kvantila definirana s

$$Q(p) = \inf \{x \in \mathbb{R} : F(x) \geq p\}, \quad p \in (0, 1)$$

i ako je F neprekidna i strogo rastuća, onda je $Q = F^{-1}$. U nastavku pretpostavljamo da je $Q = F^{-1}$. Posebno, X je neprekidna slučajna varijabla.

Za zadani p_0 , želimo testirati da je p_0 -kvantil $Q(p_0)$ jednak nekoj unaprijed zadanoj vrijednosti x_0

$$H_0 : Q(p_0) = x_0.$$

Primjerice,

$$H_0 : Q(0.5) = x_0 \quad \text{medijan od } X \text{ je } x_0.$$

Uočimo da je

$$Q(p_0) = x_0 \Leftrightarrow F(Q(p_0)) = F(x_0) \Leftrightarrow p_0 = F(x_0),$$

pa hipotezu možemo ekvivalentno postaviti kao

$$H_0 : F(x_0) = p_0 \Leftrightarrow H_0 : P(X \leq x_0) = p_0$$

čime test svodimo na testiranje hipoteze o vjerojatnosti:

$$H_0 : \theta = \theta_0,$$

gdje je $\theta_0 = p_0$ i $\theta = P(X \leq x_0)$ nepoznati parametar. Ovakvu hipotezu možemo testirati binomnim testom. Odgovarajući uzorak je

$$(I_{\{X_1 \leq x_0\}}, \dots, I_{\{X_n \leq x_0\}})$$

i test statistika

$$T = \sum_{i=1}^n I_{\{X_i \leq x_0\}},$$

što je broj X_i koji su manji od x_0 . U uvjetima H_0 je $T \sim \mathcal{B}(n, \theta_0)$.

Za dvostrani test imamo

$$\begin{array}{llll} H_0 : Q(p_0) = x_0 & \Leftrightarrow & H_0 : F(x_0) = p_0 & \Leftrightarrow & H_0 : \theta = p_0 \\ H_1 : Q(p_0) \neq x_0 & \Leftrightarrow & H_1 : F(x_0) \neq p_0 & \Leftrightarrow & H_1 : \theta \neq p_0 \end{array}$$

gdje je $\theta = P(X \leq x_0)$.

Za jednostrane testove imamo

$$\begin{array}{llll} H_0 : Q(p_0) = x_0 & \Leftrightarrow & H_0 : F(x_0) = p_0 & \Leftrightarrow & H_0 : \theta = p_0 \\ H_1 : Q(p_0) > x_0 & \Leftrightarrow & H_1 : F(x_0) < p_0 & \Leftrightarrow & H_1 : \theta < p_0 \end{array}$$

gdje smo koristili činjenicu da je F strogo rastuća pa je

$$Q(p_0) > x_0 \Leftrightarrow F(Q(p_0)) > F(x_0) \Leftrightarrow p_0 > F(x_0) \Leftrightarrow F(x_0) < p_0.$$

Za drugi jednostrani test slično imamo

$$\begin{aligned} H_0 : Q(p_0) = x_0 &\Leftrightarrow H_0 : F(x_0) = p_0 &\Leftrightarrow H_0 : \theta = p_0 \\ H_1 : Q(p_0) < x_0 &\Leftrightarrow H_1 : F(x_0) > p_0 &\Leftrightarrow H_1 : \theta > p_0. \end{aligned}$$

Treba uočiti da je test o kvantilima egzaktna pa je primjenjiv i na male uzorke. Primjerice, kada je t -test neprimjenjiv, možemo testom o kvantilima testirati hipotezu od medijanu kao drugoj mjeri sredine distribucije.