

III.7. Testiranje hipoteza o distribuciji općenito

7.1. Testiranje hipoteze o distribuciji za diskretne distribucije (χ^2 test)

Zadatak 1. U 60 bacanja nekog novčića, pismo se okrenulo 40 puta, a glava 20 puta. Možemo li na razini značajnosti 0.05 tvrditi da novčić nije pravilan?

```
##### Zadatak 1.
#Hipoteze:
# H0: X ~ ( 0 1 )      (novčić je pravilan)
#           1/2 1/2
# H1: ne H0
#Očigledno je da dani uzorak favorizira pismo (1).
#Pitanje je može li se to pripisati slučajnosti ili tu ima nešto više od
  same slučajnosti.
that <- 6.6667          # vrijednost test-statistike
c(qchisq(0.95, 1), Inf) # kritično područje
1 - pchisq(that, 1)     # p-vrijednost

#Sintaksa za \chi^2 test: chisq.test(x, p = vjer)
#x je vektor opaženih frekvencija, a p je vektor vjerojatnosti
  pretpostavljene (teorijske) distribucije
chisq.test(c(20, 40), p = c(1/2, 1/2))
#p = 0.0098 < 0.05 => Na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
  H1,
# tj. na razini značajnosti 0.05 možemo tvrditi da je novčić неправи́lan.
#Opažene frekvencije:
chisq.test(c(20, 40), p = c(1/2, 1/2))$observed
#Očekivane frekvencije:
chisq.test(c(20, 40), p = c(1/2, 1/2))$expected

#Napomena: kada teorijska distribucija ima samo dva moguća ishoda, hipoteze
  o distribuciji mogu
# se svesti na hipoteze o parametru Bernoullijeve distribucije. U tom
  slučaju bolje je koristiti
# binomni test koji je egzaktni za razliku od \chi^2 testa.
binom.test(40, 60, p = 1/2)
```

Zadatak 2. Zabilježeni su ishodi 60 bacanja kockice:

vrijednost	1	2	3	4	5	6
frekvencija	4	6	17	16	8	9

Možemo li na razini značajnosti 0.05 tvrditi da kockica nije pravilna?

```
##### Zadatak 2.
#Hipoteze:
#
#      1    2    3    4    5    6
# H0:   X ~ ( 1/6 1/6 1/6 1/6 1/6 1/6 )      (kockica je pravilna)
#
# H1: ne H0
(x <- c(4, 6, 17, 16, 8, 9))
(vjer <- rep(1/6, 6))      # ili vjer <- c(1/6, 1/6, 1/6, 1/6, 1/6, 1/6)
chisq.test(x, p = vjer)
#p = 0.01439 < 0.05 => Na razini značajnosti 0.05 odbacujemo H0 i
    prihvaćamo H1,
#tj. na razini značajnosti 0.05 možemo tvrditi da je kockica nepravilna.
```

Zadatak 3. Tržišni analitičar želi istražiti imaju li potrošači neke posebne sklonosti prema nekom od okusa sokova koji su se pojavili na tržištu. Na uzorku od 100 ljudi prikupio je preferencije prema ponuđenim okusima. Frekvencije su dane u sljedećoj tablici:

višnja	jagoda	naranča	limun	grejp
32	28	16	14	10

Ispitajte postoji li na razini značajnosti 0.05 statistički značajna preferencija potrošača prema nekom od okusa ili je sklonost potrošača jednaka prema svim ponuđenim okusima.

```
##### Zadatak 3.
#Označimo okuse redom s 1, 2, 3, 4, 5.
#Treba testirati ima li obilježje uniformnu distribuciju na peteročlanom
    skupu ili ne, tj.
#
#      1    2    3    4    5
# H0:   X ~ ( 1/5 1/5 1/5 1/5 1/5 )      (ne postoji preferencija prema
    nekom okusu)
#
# H1: ne H0
x <- c(32, 28, 16, 14, 10)
vjer <- rep(1/5, 5)
chisq.test(x, p = vjer)
#p = 0.001234 < 0.05 => Na razini značajnosti 0.05 odbacujemo H0 i
    prihvaćamo H1, tj. na razini značajnosti 0.05
#možemo tvrditi da postoji sklonost potrošača prema nekim od promatranih
    okusa sokova.
```

Zadatak 4. Jedna je studija na osnovu istraživanja o razlozima povratka na posao ljudi koji su umirovljeni postavila sljedeću distribuciju:

38% se ponovo zaposli u drugom poduzeću
 32% osnuje obrt
 23% rade kao konzultanti
 7% osnuje vlastito poduzeće

Poklapaju li se sljedeći rezultati, dobiveni ponovnim istraživanjem, s prethodno postavljenom tezom ili na razini značajnosti 0.05 možemo utvrditi postojanje statistički značajne razlike:

122 se ponovo zaposli u drugom poduzeću
 85 osnuje obrt
 76 rade kao konzultanti
 17 osnuje vlastito poduzeće

```
##### Zadatak 4.
#Označimo sve moguće ishode redom s 1, 2, 3, 4.
#Treba testirati ima li obilježje sljedeću distribuciju
#           1      2      3      4
# H0:      X ~ (
#           0.38 0.32 0.23 0.07
#
# H1: ne H0
x <- c(122, 85, 76, 17)
vjer <- c(0.38, 0.32, 0.23, 0.07)
chisq.test(x, p = vjer)
#p = 0.3485 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0, tj.
#nemamo razloga tvrditi da prvo istraživanje nije u skladu s novim
#istraživanjem.
```

Zadatak 5. Tri novčića se bace 250 puta i broji se broj pisama koji su pali. Dobiveni su sljedeći podaci:

broj pisama	0	1	2	3
frekvencija	24	108	95	23

Možemo li na razini značajnosti 0.05 tvrditi da novčići nisu pravilni?

```
##### Zadatak 5.
#Svaki od 250 puta, bacamo tri novčića. Slučajna varijabla koja broji broj
#pisama u ishodima jednog bacanja ima binomnu distribuciju.
#Ako su novčići pravilni tada će to biti binomna B(3, 1/2) distribucija
#čije vjerojatnosti su:
dbinom(0:3, 3, 1/2)
#Treba testirati ima li obilježje sljedeću distribuciju
#           0      1      2      3
# H0:      X ~ (
#           1/8  3/8  3/8  1/8
#
# H1: ne H0
```

```
x <- c(24, 108, 95, 23)
vjer <- c(1/8, 3/8, 3/8, 1/8)
chisq.test(x, p = vjer)
#p = 0.1096 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0,
#tj. nemamo razloga sumnjati da su novčići nepravilni.
```

Zadatak 6. Promatramo prvu značajnu znamenku u nekom skupu brojeva, odnosno prvu znamenku različitu od 0. Vjerojatnost slučajno odabrane znamenke iz skupa $\{1, \dots, 9\}$ je $1/9$. Međutim, kod podataka koji se pojavljuju u prirodi distribucija nije uniformna već vrijedi tzv. Benfordov zakon. Prema Benfordovom zakonu vjerojatnost da prva značajna znamenka nekog broja bude jednaka d , $d = 1, \dots, 9$, nije $1/9$ već je dana izrazom

$$\log_{10}(d+1) - \log_{10}(d).$$

Iz tablice sastavljene od 52 fizikalne konstante dobivene su sljedeće frekvencije prve značajne znamenke

d	1	2	3	4	5	6	7	8	9
frekvencije	17	11	3	5	5	4	3	1	3

Testirajte Benfordov zakon na razini značajnosti 0.05.

Testirajte Benfordov zakon za prvih 1000 Fibonaccijevih brojeva na nivou značajnosti 0.05.

```
#### Zadatak 6.
#Vjerojatnosti Benfordove distribucije dane su s
(vjer <- log10(1:9 + 1) - log10(1:9))
plot(vjer, type="h")
#Prema Benfordovom zakonu 1 je najčešća prva značajna znamenka, i
#učestalost pada do 9
#Hipoteze:
# H0: X ima Benfordovu distribuciju
# H1: X nema Benfordovu distribuciju
x <- c(17, 11, 3, 5, 5, 4, 3, 1, 3)
bp <- barplot(x/sum(x), names.arg = 1:9) # na ovaj način predajemo
# odgovarajuće koordinate stupaca
bp
lines(bp, vjer, type = "o")

chisq.test(x, p = vjer)
#p = 0.8718 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0,
#tj. ne možemo tvrditi da se distribucija razlikuje od Benfordove
# distribucije.
# Warning koji dobijemo je zato jer su neke očekivane frekvencije manje od
# 5
chisq.test(x, p = vjer)$expected

#Na Fibonaccijevim brojevima
niz <- c(0, 1)
for (i in 3:1000) {
```

```

    niz <- c(niz, niz[i-1] + niz[i-2])
  }
  x <- niz[-1]
  x

formatC(x, format='e')
substring(formatC(x, format='e'), 1, 1)
(x <- as.numeric(substring(formatC(x, format='e'), 1, 1))) #prve značajne
    znamenke Fibonaccijevih brojeva
frek <- table(x)
chisq.test(frek, p = vjer)
#p = 1 > 0.05 => Sigurno ne odbacujemo H0, nema razloga tvrditi da
    distribucija nije Benfordova.

```

Zadatak 7. Tijekom Drugog svjetskog rata Nijemci su bombardirali London. Britance je zanimalo mogu li Nijemci uistinu ciljati svoje bombe ili samo gađaju na slučajan način. Napravljena je mapa Londona podijeljena na 576 dijelova jednake površine i za 538 bombi zabilježeno je gdje su pale. Broj područja na koje je palo k bombi zabilježen je u sljedećoj tablici

bombi po području (k)	0	1	2	3	4 i više
područja s k bombi	229	211	93	35	8

Možemo li na razini značajnosti 0.05 tvrditi da gađanje nije bilo slučajno?

```

#### Zadatak 7.
#Ako su pogotci slučajni, onda svaka bomba ima jednaku vjerojatnost pasti
    na bilo koje od 576 područja.
#Za svako pojedino područje vjerojatnost pogađanja je 1/576, a broj gađanja
    je 538.
#Stoga broj pogodaka jednog područja ima binomnu distribuciju B(538, 1/576)
    .
#Podatke imamo za n=576 područja.
#Dakle, radi se o uzorku veličine 576 iz B(538, 1/576) distribucije.
#X_i - broj pogodaka u i-tom području
#(X_1, ..., X_576) - slučajan uzorak
#Uočimo da je pretpostavka nezavisnosti narušena.
#Ipak, testirat ćemo hipoteze:
# H0:  $X \sim B(538, 1/576)$ 
# H1: ne H0

#Empirijska distribucija:
podaci <- c(229, 211, 93, 35, 8)
bp <- barplot(podaci/576, names.arg = 0:4)
bp
#Sve vrijednosti veće od 4 ćemo grupirati kao jedan ishod (kategorizacija).
#Teorijska distribucija
vjer <- dbinom(0:3, 538, 1/576)
(vjer <- c(vjer, 1 - sum(vjer)))
bp

```

```
lines(bp, vjer, type = "o")
#Očekivane frekvencije u uvjetima H0:
vjer*576
podaci

chisq.test(podaci, p = vjer)
#p = 0.9041 > 0.05 => Ne odbacujemo H0 na razini značajnosti 0.05.
#Nema dokaza da su Nijemci mogli ciljati (to je u suprotnosti s vjerovanjem
  ljudi
# da su neka područja ciljano više gađana)

#Binomna distribucija može se dobro aproksimirati Poissonovom.
#Odgovarajući parametar Poissonove je lambda = np = 538/576
vjerP <- dpois(0:3, 538/576)
(vjerP <- c(vjerP, 1 - sum(vjerP)))
#Usporedite s:
vjer

#testiramo li u odnosu na Poissonovu distribuciju s parametrom 538/576:
chisq.test(podaci, p = vjerP)
#p = 0.9069 > 0.05 => Ne odbacujemo H0 na razini značajnosti 0.05.

#I ovdje smo kategorizirali sve ishode veće ili jednake 4.
#Princip kategorizacije može se iskoristiti i za neprekidne distribucije,
  ali
#rezultat može jako ovisiti o izabranoj kategorizaciji.
```

7.2. Testiranje hipoteze o distribuciji za neprekidne distribucije (Kolmogorov-Smirnovljev test i testovi normalnosti)

Zadatak 8. Na razini značivosti 0.05 testirajte dolazi li realizacija (0.07, 0.3, 0.5, 0.54, 0.95) jednostavnog slučajnog uzorka (X_1, X_2, X_3, X_4, X_5) iz $\mathcal{U}(0, 1)$ distribucije.

```
##### Zadatak 8.
#F0 – funkcija distribucije U(0,1)
#F – funkcija distribucije iz koje dolazi j.s.u. (X_1, X_2, X_3, X_4, X_5)
#Hipoteze:
# H0: F = F0 (F(x)=F0(x), za svaki realan broj x)
# H1: F != F0 (postoji realan broj x takav da je F(x)!=F0(x))
#R funkcija: ks.test()
#prvi argument su podaci, drugi argument je string koji daje naziv
# odgovarajuće
#funkcije distribucije u R-u, zatim se navode parametri te distribucije.
podaci <- c(0.07, 0.3, 0.51, 0.54, 0.95)
ks.test(podaci, "punif", 0, 1)
#p = 0.8123 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0, tj. nema
# razloga
#sumnjati da podaci dolaze iz U(0,1) distribucije.
#Test je egzaktn pa ga možemo primijeniti i na ovako malo uzorku.
```

Zadatak 9. Datoteka *farmakologija.csv* sadrži podatke o koncentraciji nekog lijeka u organizmu za 101 mjerenje provedeno od trenutka unosa lijeka u organizam do trenutka njegove eliminacije iz organizma (varijabla **koncentracija-lijeka**). Nacrtajte histogram. Sugerira li on neku teorijsku neprekidnu distribuciju iz koje dolaze ti podaci? Na razini značajnosti 0.05 testirajte hipotezu da ti podaci dolaze iz eksponencijalne distribucije s parametrom 0.5.

```
##### Zadatak 9.
farmakologija <- read.csv2("farmakologija.csv")
str(farmakologija)
lijeak <- farmakologija$koncentracija_lijeka
#Grafički prikazi koji sugeriraju teorijsku distribuciju koncentracije
# lijeka
hist(lijeak, probability = T)
curve(dexp(x, 0.5), col = "blue", add = T)
plot(density(lijeak), col = "red")
curve(dexp(x, 0.5), col = "blue", add = T)
#Procjena parametra eksponencijalne distribucije
(lambda <- 1 / mean(lijeak))
#F0 – funkcija distribucije eksponencijalne distribucije s parametrom 0.5
#F – funkcija distribucije koncentracije lijeka
#Hipoteze:
# H0: F = F0 (F(x)=F0(x), za svaki realan broj x)
```

```
# H1: F != F0 (postoji realan broj x takav da je F(x) != F0(x))
ks.test(lijek, "pexp", 0.5)
#p = 6.562e-08 < 0.05 => Na razini značajnosti 0.05 odbacujemo H0 i
  prihvaćamo H1,
#tj. ne možemo tvrditi da je koncentracija lijeka eksponencijalno
  distribuirana s parametrom 0.5.
```

Zadatak 10. U datoteci *zarulje.csv* nalaze se podaci o životnom vijeku 100 žarulja. Grafičkim prikazom se uvjerite da je sugerirana distribucija vremena trajanja žarulje eksponencijalna distribucija, a zatim na razini značajnosti 0.05 testirajte hipotezu da podaci o vremenu trajanja žarulja dolaze iz eksponencijalne distribucije s parametrom 0.005.

```
#### Zadatak 10.
zarulje <- read.csv2("zarulje.csv")
str(zarulje)
x <- zarulje$trajanje
#Grafički prikazi koji sugeriraju teorijsku distribuciju vremena trajanja
  žarulje
plot(density(x), col = "red")
curve(dexp(x, 0.005), col = "blue", add = T)
hist(x, probability = T)
curve(dexp(x, 0.005), col = "blue", add = T)
#procjena parametra eksponencijalne distribucije
(lambda <- 1 / mean(x))
#F0 – funkcija distribucije eksponencijalne distribucije s parametrom 0.005
#F – funkcija distribucije vremena trajanja žarulje
#Hipoteze:
# H0: F = F0 (F(x)=F0(x), za svaki realan broj x)
# H1: F != F0 (postoji realan broj x takav da je F(x) != F0(x))
ks.test(x, "pexp", 0.005)
#p = 0.2802 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0,
#tj. nema razloga sumnjati da vrijeme trajanja žarulje ima E(0.005)
  distribuciju.
```

Zadatak 11. U datoteci *automobili.csv* nalaze se rezultati mjerenja potrošnje goriva novog tipa automobila pri brzini od 110 km/h na autocesti za 300 nezavisnih mjerenja (varijabla *potrosnja*). Na razini značajnosti 0.05 testirajte hipotezu o normalnosti distribucije kojom modeliramo ovu potrošnju.

```
#### Zadatak 11.
auti <- read.csv2("automobili.csv")
str(auti)
potrosnja <- auti$potrosnja
hist(potrosnja, freq = F)
plot(density(potrosnja))
#Parametri normalne distribucije su nepoznati – koristimo Shapiro–Wilkov
  test
```



```
#Hipoteze:
# H0: uzorak dolazi iz (neke) normalne distribucije
# H1: uzorak ne dolazi iz normalne distribucije
shapiro.test(potrosnja)
#p = 0.7163 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0,
#tj. nema razloga sumnjati u normalnu distribuiranost potrošnje.
```

Zadatak 12. U datoteci *cvrstoca.csv* nalaze se mjerenja čvrstoće čelične žice. Na razini značajnosti 0.05 testirajte hipotezu o normalnoj distribuiranosti distribucije uzorka. Na razini značajnosti 0.05 testirajte hipotezu da ti podaci dolaze iz $N(300, 289)$ distribucije.

```
#### Zadatak 12.
cvrstoca <- read.csv2("cvrstoca.csv")
str(cvrstoca)
x <- cvrstoca$cvrstoca
#Test normalnosti:
#Hipoteze:
# H0: čvrstoće čelične žice ima normalnu distribuciju
# H1: čvrstoće čelične žice nema normalnu distribuciju
shapiro.test(x)
#p = 0.8032 > 0.05 => na razini značajnosti 0.05 ne odbacujemo H0,
#tj. nema razloga sumnjati u normalnu distribuiranost čvrstoće žice.
#Veličina uzorka je mala, ali unatoč tome možemo primijeniti Shapiro–Wilk
  test.
#(svakako treba oprezno zaključivati)

#F0 – funkcija distribucije N(300,289) distribucije
#F – funkcija distribucije čvrstoće čelične žice
#Hipoteze:
# H0:  $F(x)=F_0(x)$ , za svaki realan broj x (čvrstoća čelične žice ima N
  (300,289) distribuciju)
# H1: postoji realan broj x t.d. je  $F(x) \neq F_0(x)$  (čvrstoće čelične žice
  nema N(300,289) distribuciju)
ks.test(x, "pnorm", 300, sqrt(289))
#p = 0.4358 > 0.05 => na razini značajnosti 0.05 ne odbacujemo H0,
#tj. nema razloga sumnjati u N(300,289) distribuciju čvrstoće žice.
```

Zadatak 13. U datoteci *ChickWeight* nalaze se podaci o masi pilića mjerenima po danima od njihova rođenja. Promotrimo samo mase pilića starih točno 18 dana. Testirajte je li na razini značajnosti 0.05 masa pilića starih točno 18 dana normalno distribuirana.

```
#### Zadatak 13.
#Hipoteze:
# H0: masa pilića starih 18 dana ima normalnu distribuciju
# H1: masa pilića starih 18 dana nema normalnu distribuciju
#Shapiro–Wilkov test
str(ChickWeight)
```

```
x <- ChickWeight$weight[ChickWeight$Time==18]
shapiro.test(x)
#p=0.9749 > 0.05 => Na razini značajnosti 0.05 ne odbacujemo H0,
#tj. nema razloga sumnjati u normalnu distribuiranost mase pilića.
```