

III.7. Testiranje hipoteza o distribuciji općenito

Sadržaj

1. χ^2 test	1
2. Kolmogorov - Smirnovljev test	4
3. Testovi normalnosti	5

Neka je $\mathbf{X} = (X_1, \dots, X_n)$ j.s.u. iz funkcije distribucije F koja je nepoznata. Želimo testirati hipotezu o jednakosti funkcije distribucije F nekoj zadanoj distribuciji s funkcijom distribucije F_0 :

$$H_0 : F(x) = F_0(x) \text{ za sve } x \in \mathbb{R}.$$

Odgovarajući test biramo prema tipu distribucije F_0 . U literaturi se ovi testovi nazivaju „goodness of fit” testovi, što bi se moglo prevesti kao „kvaliteta prilagodbe”, u smislu koliko dobro pretpostavljena distribucija odgovara podacima.

1. χ^2 test

χ^2 test koristimo kada je F_0 diskretna distribucija s konačnom slikom

$$F_0 \sim \begin{pmatrix} y_1 & \cdots & y_m \\ p_1^0 & \cdots & p_m^0 \end{pmatrix}.$$

Hipoteze su:

$$H_0 : F(x) = F_0(x) \text{ za sve } x \in \mathbb{R},$$

$$H_1 : \text{postoji } x \in \mathbb{R} \text{ takav da je } F(x) \neq F_0(x).$$

Obično u ovom slučaju pišemo za $X \sim F$

$$H_0 : X \sim \begin{pmatrix} y_1 & \cdots & y_m \\ p_1^0 & \cdots & p_m^0 \end{pmatrix},$$

$$H_1 : \text{ne } H_0.$$

Za definiranje test statistike trebaju nam dvije veličine:

- **Opažene (empirijske) frekvencije** vrijednosti y_k , $k = 1, \dots, m$ definirane slučajnim varijablama

$$f_k = \sum_{i=1}^n I_{\{X_i=y_k\}}, \quad k = 1, \dots, m.$$

- **Očekivane (teorijske) frekvencije** vrijednosti y_k , $k = 1, \dots, m$ definirane s

$$np_k^0, \quad k = 1, \dots, m$$

(to su frekvencije koje bi očekivali ako vrijedi H_0).

Test statistika

$$T(\mathbf{X}) = \sum_{k=1}^m \frac{(f_k - np_k^0)^2}{np_k^0}$$

u uvjetima istinitosti hipoteze H_0 asimptotski ima χ_{m-1}^2 distribuciju, pri čemu je m kardinalni broj od $\mathcal{R}(X)$ (ne treba miješati s dimenzijom uzorka n). Primijetimo:


$$\frac{f_k - np_k^0}{\sqrt{np_k^0}} = \frac{\frac{1}{n} \sum_{i=1}^n I_{\{X_i=y_k\}} - p_k^0}{\sqrt{p_k^0}} \sqrt{n} \frac{\sqrt{1-p_k^0}}{\sqrt{1-p_k^0}} \xrightarrow{D} \sqrt{1-p_k^0} \mathcal{N}(0, 1), \quad \text{kada } n \rightarrow \infty.$$

Dakle, statistika $T(\mathbf{X})$ je asimptotski suma kvadrata normalnih distribucija, ali one nisu nezavisne. Dodatni argumenti pokazuju χ_{m-1}^2 distribuciju u limesu.

Uočimo da u prilog alternativnoj hipotezi H_1 idu veće vrijednosti $T(\mathbf{X})$ (veći kvadrati ostupanja opaženih od očekivanih frekvencija). Stoga je kritično područje oblika

$$C = [h_{m-1,\alpha}, \infty),$$

gdje je $h_{m-1,\alpha} = Q_{\chi_{m-1}^2}(1-\alpha)$ $(1-\alpha)$ -kvantil χ^2 distribucije s $m-1$ stupnjeva slobode (vidi sliku).



Za realizaciju test statistike $\hat{t}$, p -vrijednost možemo izračunati kao

$$p = P_{F_0}(T(\mathbf{X}) \geq \hat{t}) \approx P(\chi_{m-1}^2 \geq \hat{t}).$$

Prilikom korištenja χ^2 testa treba voditi računa o sljedećem:

- χ^2 je asimptotski test, stoga je bitno da aproksimacija distribucije test statistike bude dovoljno dobra. Uobičajeno pravilo u literaturi jest da sve očekivane frekvencije moraju biti barem 5 (iako radi se o prestrogom uvjetu i zapravo je često puno manje dovoljno).

- Ukoliko je F_0 diskretna distribucija s beskonačnom slikom, velik broj opaženih frekvencija bit će 0. U tom slučaju realizacije se mogu kategorizirati tako da daju distribuciju s konačnom slikom te se na tom problemu primijeni χ^2 test.

Primjer 1. U 60 bacanja nekog novčića, pismo se okrenulo 40 puta, a glava 20 puta. Možemo li na razini značajnosti 0.05 tvrditi da novčić nije pravilan?

Uzorak $\mathbf{X} = (X_1, \dots, X_{60})$ dolazi iz Bernoullijeve distribucije

$$X \sim \begin{pmatrix} 0 & 1 \\ 1 - \theta & \theta \end{pmatrix} = F, \quad \theta \in (0, 1),$$

gdje 1 označava pismo, a $\theta = P(X = 1)$ je nepoznati parametar. Slično kao u Primjeru 1. -poglavlje III.5-6. i ovdje možemo postaviti hipoteze u terminu nepoznatog parametra

$$\begin{aligned} H_0 : \theta &= \frac{1}{2} && \text{novčić je pravilan,} \\ H_1 : \theta &\neq \frac{1}{2} && \text{novčić nije pravilan,} \end{aligned}$$

i provesti binomni test. Međutim, u svrhu ilustriranja kreiranog χ^2 testa hipoteze postavljamo u terminu distribucija:

$$\begin{aligned} H_0 : X &\sim \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} && (\text{novčić je pravilan}), \\ H_1 : &\text{ne } H_0 && (\text{novčić nije pravilan}). \end{aligned}$$

Dakle,

$$F_0 \sim \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}.$$

Kako bismo izračunali realizaciju test statistike $\hat{t}$ trebaju nam

	0	1
opažene frekvencije	20	40
očekivane frekvencije	30	30

Sada je

$$\hat{t} = \frac{(20 - 30)^2}{30} + \frac{(40 - 30)^2}{30} = \frac{20}{30} = 6.667$$

Kako je $T(\mathbf{X}) \sim^A \chi_1^2$ ($m = 2$) kritično područje je

$$C = [3.841, \infty),$$

što jednostavno dobijemo u R-u funkcijom `qchisq()`. Vidimo da je $\hat{t} \in C$ pa odbacujemo hipotezu H_0 u korist alternativne hipoteze H_1 na razini značajnosti 0.05. Možemo tvrditi da uzorak ne dolazi iz zadane distribucije F_0 , odnosno da novčić nije pravilan.

Isti zaključak možemo dobiti i koristeći p -vrijednost:

$$p = P(\chi_1^2 \geq \hat{t}) = 0.0098 < \alpha$$

Ukoliko bismo hipoteze testirali binomnim testom dobili bi p -vrijednost 0.0135.

Općenito, kada distribucija uzorka ima samo dva moguća ishoda, hipoteze distribucije mogu se svesti na hipoteze o parametru Bernoullijeve distribucije. U tom slučaju bolje je koristiti binomni test koji je egzaktni za razliku od χ^2 -testa.

Ukoliko raspoložemo uzorkom iz neprekidne slučajne varijable X , χ^2 -test mogli bi provesti tako da najprije sliku slučajne varijable $\mathcal{R}(X)$ podijelimo na konačno mnogo disjunktih intervala i dalje postupamo kao u slučaju diskretne distribucije. Međutim, pokazuje se da je taj postupak jako osjetljiv na izbor podjele $\mathcal{R}(X)$ te se stoga ne preporuča korištenje χ^2 -testa u tom slučaju.

2. Kolmogorov - Smirnovljev test

Za uzorke iz neprekidnih distribucija, alternativa χ^2 -testu je Kolmogorov-Smirnovljev test (KS test). Hipoteze su:

$$H_0 : F(x) = F_0(x) \text{ za sve } x \in \mathbb{R},$$

$$H_1 : \text{postoji } x \in \mathbb{R} \text{ takav da je } F(x) \neq F_0(x).$$

Moguće je promatrati i jednostrane alternativne hipoteze, ali to nećemo raditi ovdje. Test statistika temelji se na razlici između empirijske funkcije distribucije

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq x\}}$$

i pretpostavljene teorijske distribucije F_0 , te je definirana s

$$D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_0(x)|.$$

U uvjetima istinitosti hipoteze H_0 , D_n ima distribuciju koja ovisi samo o veličini uzorka n , ali ne i o funkciji distribucije F . Skicirat ćemo ukratko ovu naizgled iznenađujuću činjenicu. Neka je F^{-1} inverz od F (generalizirani inverz koji je dobro definiran jer je F neprekidna distribucija). Zamjenom varijabli

$$x = F^{-1}(y), \quad y = F(x),$$

slijedi

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_0(x)| = \sup_{y \in [0,1]} |\hat{F}_n(F^{-1}(y)) - F_0(F^{-1}(y))| = \sup_{y \in [0,1]} |\hat{F}_n(F^{-1}(y)) - y|,$$

gdje je u zadnjoj jednakosti korištena činjenica da je $F(x) = F_0(x)$ za sve $x \in \mathbb{R}$ u uvjetima istinitosti H_0 . Dalje,

$$\hat{F}_n(F^{-1}(y)) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq F^{-1}(y)\}} = \frac{1}{n} \sum_{i=1}^n I_{\{F(X_i) \leq y\}}.$$

Slučajne varijable $U_i = F(X_i)$, $i = 1, \dots, n$ su n.j.d. iz $\mathcal{U}(0, 1)$ distribucije. Stoga

$$D_n \stackrel{d}{=} \sup_{y \in [0, 1]} \left| \frac{1}{n} \sum_{i=1}^n I_{\{U_i \leq y\}} - y \right|,$$

što ne ovisi o F . Veće vrijednosti test statistike idu u prilog alternativnoj hipotezi H_1 pa će kritično područje biti oblika

$$C = [d_{n,\alpha}, \infty),$$

gdje je $d_{n,\alpha}$ $(1 - \alpha)$ -kvantil distribucije od D_n . Egzaktnu distribuciju test statistike D_n nećemo izvoditi. U R-u egzaktna distribucija se koristi za uzorke do veličine $n = 100$, a za veće uzorke koristi se asimptotska distribucija od $\sqrt{n}D_n$, poznata kao Kolmogorovljeva distribucija s funkcijom distribucije

$$K(x) = 1 - 2 \sum_{k=1}^n (-1)^{k-1} e^{-2k^2 x^2}, \quad x > 0.$$

3. Testovi normalnosti

Vidjeli smo da se brojni testovi oslanjaju na pretpostavku normalnosti distribucije uzorka. Stoga je čest problem testirati hipoteze

H_0 : uzorak dolazi iz (neke) normalne distribucije,

H_1 : uzorak ne dolazi iz normalne distribucije

Bitna razlika u odnosu na KS test jest da teorijska distribucija nije jednoznačno određena (parametri μ i σ^2 su nepoznati). Mogli bismo uvrstiti procjene za μ i σ^2 i provesti KS test. Međutim, distribucija test statistike D_n se time mijenja i nije korektno koristiti KS test. Postoji posebna verzija, tzv. Lillieforsova verzija KS testa za testiranje normalnosti uzorka. Postoje i brojni drugi testovi za ove hipoteze, od kojih kao bolji izdvajamo Shapiro-Wilk test.