

IV.5. Testovi o očekivanju za vezane slučajne uzorke

Zadatak 1. *Datoteka djelatnici.csv sadrži visine godišnjih plaća u eurima za uzorak od 100 zaposlenika jednog poduzeća - varijabla placa_prije sadrži plaće prije, a varijabla placa_poslije plaće nakon restrukturiranja tog poduzeća. Možemo li na razini značajnosti 0.05 tvrditi da je očekivana godišnja plaća zaposlenika tog poduzeća porasla nakon restrukturiranja?*

```
##### Zadatak 1.
#mu1 - očekivana plaća prije restrukturiranja poduzeća
#mu2 - očekivana plaća nakon restrukturiranja poduzeća
#Radi se o vezanim uzorcima jer promatramo plaće istog djelatnika.
#Parovi podataka dolaze od nezavisnih i jednako distribuiranih slučajnih
vektora.
#Komponente tih slučajnih vektora ne moraju biti nezavisne (i nisu jer
modeliraju plaće istog zaposlenika).
#Hipoteze:
# H0: mu1 = mu2      (očekivane plaće su jednake)
# H1: mu1 < mu2      (Očekivana plaća je veća nakon restrukturiranja)
djelatnici <- read.csv2("djelatnici.csv")
str(djelatnici)
attach(djelatnici)
#Uvijek je dobro grafički promotriti razlike:
boxplot(placa_prije, placa_poslije)
boxplot(placa_prije - placa_poslije)
#Uzorci su dovoljno veliki za primjenu t-testa.
t.test(placa_prije, placa_poslije, alternative = "less", paired = TRUE)
#p < 0.05 - na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo H1,
# možemo tvrditi da je očekivana godišnja plaća porasla nakon
restrukturiranja.
#Radi se o testu na uzorku razlika:
razlike <- placa_prije - placa_poslije
#uz hipoteze:
# H0: muD = mu1-mu2 = 0
# H1: muD = mu1-mu2 < 0
t.test(razlike, mu=0, alternative = "less")
#Važno je uočiti da se radi o vezanim uzorcima jer zaključak može biti
potpuno drukčiji:
t.test(placa_prije, placa_poslije, alternative = "less")
```

Zadatak 2. *Tablica Stress iz paketa BSDA sadrži neke rezultate istraživanja o povezanosti stresa i kratkoročnog pamćenja. Kratkoročno pamćenje testirano je na uzorku od dvanaest ispitanika prije i nakon izlaganja istoj stresnoj situaciji. Rezultati tih testova sadržani su u varijablama Prestress i Poststress. Možemo li, uz pretpostavku o normalnoj distribuiranosti*

razlika rezultata testiranja prije i nakon izlaganja stresnoj situaciji, na razini značajnosti 0.05 tvrditi da je očekivani rezultat na testu nakon izlaganja stresu niži od očekivanog rezultata prije stresne situacije?

```
##### Zadatak 2.
#Radi se o vezanim uzorcima jer je test na istoj osobi.
# mu1 – očekivani rezultat na testu prije izlaganja stresnoj situaciji
# mu2 – očekivani rezultat na testu nakon izlaganja stresnoj situaciji
#Hipoteze:
# H0: mu1 = mu2
# H1: mu1 > mu2
library("BSDA")
Stress
attach(Stress)
mean(prestress)
mean(poststress)
boxplot(prestress, poststress)
#S obzirom na pretpostavku normalne distribuiranosti razlika, možemo
koristiti t-test.
t.test(prestress, poststress, alternative = "greater", paired = TRUE)
#p=0.01231 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
H1,
# možemo tvrditi da je je očekivani rezultat na testu niži nakon izlaganja
stresu.
```

Zadatak 3. *Nakon rehabilitacije zatvorenici prolaze psihijatrijsko testiranje, a kako bi se osigurala objektivnost ocjenjuju ih dva psihijatra. Rezultati se nalaze u bazi podataka Rehab iz paketa BSDA. Pod pretpostavkom da su razlike ocjena normalno distribuirane, testirajte razlikuju li se očekivane ocjene dvaju psihijatara na razini značajnosti 0.05?*

```
##### Zadatak 3.
#Radi se o vezanim uzorcima jer se radi o ocjenama na istoj osobi.
# mu1 – očekivani rezultat prvog psihijatra
# mu2 – očekivani rezultat drugog psihijatra
#Hipoteze:
# H0: mu1 = mu2
# H1: mu1 != mu2
library("BSDA")
Rehab
attach(Rehab)
mean(psych1)
mean(psych2)
boxplot(psych1, psych2)
t.test(psych1, psych2, alternative = "two.sided", paired = TRUE)
#p=0.4022 > 0.05 – na razini značajnosti 0.05 ne odbacujemo H0,
# nema razloga tvrditi da se ocjene značajno razlikuju.
```

IV.6. Test o proporciji za vezane slučajne uzorke

Zadatak 4. 70 djece u dobi od 12 godina je ispitano jesu li u posljednjih 12 mjeseci imali prehladu te im je isto pitanje postavljeno kad su imali 14 godina. Njih 37 je oba puta odgovorilo negativno, 10 ih je bilo prehladeno samo u dobi od 12 godina, 15 samo u dobi od 14 godina, a 8 je bilo prehladeno u oba razdoblja. Je li na razini značajnosti 0.05 pojava prehlade veća u dobi od 14 godina nego u dobi od 12 godina?

```
#### Zadatak 4.
#Radi se o usporedbi proporcija u vezanim uzorcima.
# theta1 – proporcija prehladenih u dobi od 12 godina
# theta2 – proporcija prehladenih u dobi od 14 godina
# Hipoteze: H0: theta1 = theta2
#           H1: theta1 < theta2
#što se svodi na
# Hipoteze: H0:  $\bar{\theta} = 0.5$ 
#           H1:  $\bar{\theta} < 0.5$ 
#Retci 12 godina i stupci 14 godina:
tab <- matrix(c(37, 15, 10, 8), 2, 2, byrow = T)
rownames(tab) <- c(0, 1)
colnames(tab) <- c(0, 1)
tab
#Broj pozitivnih razlika (parova (1,0)): 10
#Broj ne-nul razlika (parova (1,0) i (0,1)): 10+15=25
binom.test(10, 25, p = 0.5, alternative = "less")
#p=0.2122 > 0.05 ne odbacujemo H0, proporcija prehlada u dobi od 12 godina
  nije značajno manja.
```

Zadatak 5. Skupina ljudi anketirana je o tome za kojeg predsjedničkog kandidata su glasali na izborima u SAD-u 2004. i 2008. godine. Oba puta za kandidata demokratske stranke glasalo je 175 ispitanih, a oba puta za republikanskog kandidata 188 ispitanih. 26 ih je promijenilo svoj izbor s demokratskog na republikanskog kandidata, a 44 obratno. Možemo li na razini značajnosti 0.05 tvrditi da se proporcija glasača za demokrate značajno povećala?

```
#### Zadatak 5.
#S obzirom da se promatra odgovor istog ispitanika u dva vremenska trenutka
  , radi se o vezanim uzorcima.
#Kao uspjeh možemo promatrati glas za demokrate.
# theta1 – proporcija demokratskih glasača u 2004.
# theta2 – proporcija demokratskih glasača u 2008.
# Hipoteze: H0: theta1 = theta2
#           H1: theta1 < theta2
```

```

#što se svodi na
# Hipoteze:  $H_0: \bar{\theta} = 0.5$ 
#            $H_1: \bar{\theta} < 0.5$ 
#Retci 2004. godina i stupci 2008. godina:
tab <- matrix(c(188, 44, 26, 175), 2, 2, byrow = T)
rownames(tab) <- c(0, 1)
colnames(tab) <- c(0, 1)
tab
#Broj pozitivnih razlika (parova (1,0)): 26
#Broj ne-nul razlika (parova (1,0) i (0,1)): 26+44=70
binom.test(26, 70, p = 0.5, alternative = "less")
#p=0.0207 < 0.05 odbacujemo  $H_0$ , proporcija demokratskih glasača značajno se
  povećala.

#Pretpostavimo da smo iste rezultate dobili na nezavisnim uzorcima (drugi
  ispitanici).
margin.table(tab, 1)
margin.table(tab, 2)
#To znači 2004. 201 je od 433 ispitanika je glasao za demokrata,
# a 2008. 219 od 433 ispitanika je glasao za demokrata.
#U tom slučaju ne bi odbacili nul-hipotezu:
prop.test(c(201, 219), c(433, 433), alternative = "less")
#Treba uočiti da je preciznost veća na vezanim uzorcima.

```

Zadatak 6. Na osnovu podataka iz tablice `djelatnici.csv` (vidi Zadatak 1.) provjerite možemo li na razini značajnosti 0.05 tvrditi da se proporcije plaća manjih od 25000 razlikuju prije i poslije restrukturiranja?

```

#### Zadatak 6.
#Radi se o vezanim uzorcima jer promatramo plaće istih djelatnika.
# theta1 – proporcija plaća manjih od 25000 prije restrukturiranja
# theta2 – proporcija plaća manjih od 25000 poslije restrukturiranja
# Hipoteze:  $H_0: \theta_1 = \theta_2$ 
#            $H_1: \theta_1 \neq \theta_2$ 
#što se svodi na
# Hipoteze:  $H_0: \bar{\theta} = 0.5$ 
#            $H_1: \bar{\theta} \neq 0.5$ 
djelatnici <- read.csv2("djelatnici.csv")
str(djelatnici)
attach(djelatnici)
table(placa_prije < 25000, placa_poslije < 25000)
#Broj pozitivnih razlika (parova (1,0)): 8
#Broj ne-nul razlika (parova (1,0) i (0,1)): 8+1=9
binom.test(8, 9, p = 0.5, alternative = "two.sided")
#p=0.03906 < 0.05 odbacujemo  $H_0$ , proporcije se razlikuju.

```

IV.7. χ^2 -test o nezavisnosti

Zadatak 7. U tablici knjiga.csv nalaze se rezultati istraživanja o navikama čitanja (oznake: 0 - osoba ne čita redovito, 1 - osoba čita redovito) s obzirom na spol (oznake: Z - ženski spol, M - muški spol) i stručnu spremu osobe (oznake: 1 - NSS, 2 - SSS, 3 - VSS). Možemo li na razini značajnosti 0.05 tvrditi da navika čitanja ovisi o stručnoj spremi? Ovisi li o spolu?

```
##### Zadatak 7.
#Za prvo pitanje radi se o dva obilježja:
# X - čita li osoba redovito (0 - ne, 1 - da)
# Y - stručna sprema osobe (1 - NSS, 2 - SSS, 3 - VSS)
#Uzorak: (X1, Y1), ... (XN, YN) - nezavisni slučajni vektori jednako
distribuirani kao (X, Y)
#Pitanje: jesu li X i Y nezavisne slučajne varijable?
#Uočimo da niti jedna margina nije fiksirana.
knjiga <- read.csv2("knjiga.csv")
str(knjiga)
attach(knjiga)
#Analizirajmo za početak dostupne podatke
(tf <- table(citanje, obrazovanje)) # zajednička tablica frekvencija
obilježja citanje i obrazovanje
prop.table(tf) # procjena zajedničke tablice
distribucije obilježja citanje i obrazovanje
#procjene marginalnih distribucija dobijemo doadavanjem margina na
zajedničku tablicu relativnih frekvencija
addmargins(prop.table(tf))
#margine možemo dobiti i s
margin.table(tf, 1) # tablica frekvencija obilježja
citanje
#što je isto kao
table(citanje)
prop.table(margin.table(tf, 1)) # procjena marginalne distribucije za
obilježje citanje
#isto kao
prop.table(table(citanje))

prop.table(tf, 1) # procjene uvjetnih distribucija obilježja
obrazovanje
prop.table(tf, 2) # procjene uvjetnih distribucija obilježja citanje
#Ako su nezavisne, uvjetne distribucije bi trebale biti jednake
marginalnima, odnosno
prop.table(tf, 1)
#sve jednake
prop.table(margin.table(tf, 2))
#i
prop.table(tf, 2)
#sve jednake
```

```

prop.table(margin.table(tf, 1))

#Hipoteze:
# H0: navika čitanja i stručna sprema su nezavisne (X i Y su nezavisne)
# H1: navika čitanja i stručna sprema nisu nezavisne
#Možemo testirati  $\chi^2$  testom za nezavisnost
chisq.test(table(citanje, obrazovanje))
#p = 0.001817 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i
    prihvaćamo H1,
# možemo tvrditi da su navika čitanja i stručna sprema zavisna obilježja.
#Posebno, to znači i da uvjetne distribucije navike čitanja nisu jednake s
    obzirom na različite kategorije obrazovanja,
# odnosno uvjetne distribucije obrazovanja s obzirom na čitanje nisu
    jednake (u tom smislu nema homogenosti uvjetnih distribucija).

#Kako se provodi test:
# empirijske frekvencije:
tf
# očekivane frekvencije u uvjetima H0:
(N <- sum(tf))
of <- c(prop.table(margin.table(tf, 1))[1] * prop.table(margin.table(tf, 2)
    ) * N, prop.table(margin.table(tf, 1))[2] * prop.table(margin.table(tf,
    2)) * N)
(of <- matrix(of, 2, 3, byrow = TRUE))

(teststat <- sum((tf-of)^2/of))
#p-vrijednost:
1-pchisq(teststat, 1*2)

#Drugo pitanje – obilježja su:
# X – čita li osoba redovito (0 – ne, 1 – da)
# Y – spol
# $\chi^2$  testom za nezavisnost testiramo
#Hipoteze:
# H0: navika čitanja i spol su nezavisni
# H1: navika čitanja i spol nisu nezavisni
(tf <- table(citanje, spol))
chisq.test(tf)
#p = 0.00608 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
    H1,
# možemo tvrditi da su navika čitanja i spol zavisna obilježja
#Napomena: u slučaju 2x2 tablica chisq.test koristi Yatesovu korekciju zbog
    neprekidnosti
# zbog koje je definicija test statistika nešto drugačija nego u prethodnom
    primjeru

#Uočimo: H0 kao hipoteza homogenosti bi bila "navika čitanja je jednako
    distribuirana među muškarcima i ženama" ili
# "spol je jednako distribuiran među osobama koje redovito čitaju i onima
    koji ne čitaju redovito"

```

```
#Ako bi promatrali hipotezu homogenosti, u ovom konkretnom primjeru mogli
  bi koristiti i
# test o usporedbi proporcija jer se radi o 2x2 tablici.
```

Zadatak 8. Neki fakultet ima četiri smjera: elektrotehnika, brodogradnja, strojarstvo i računarstvo. Odabran je slučajni uzorak od 500 studenata. Dobiveni podaci dani su u sljedećoj tablici:

	elektrotehnika	brodogradnja	strojarstvo	računarstvo	Σ
student	100	80	70	50	300
studentica	50	50	50	50	200
Σ	150	130	120	100	500

Možemo li na razini značajnosti 0.05 tvrditi da odabir smjera ovisi o spolu?

```
##### Zadatak 8.
#Hipoteze:
# H0: odabir smjera ne ovisi o spolu
# H1: postoji zavisnost
#Možemo testirati  $\chi^2$  testom o nezavisnosti.
(tf <- matrix(c(100, 80, 70, 50, 50, 50, 50, 50), 2, 4, byrow = TRUE))
chisq.test(tf)
#p=0.06545 > 0.05 – na razini značajnosti 0.05 ne odbacujemo H0,
# tj. ne možemo tvrditi da odabir smjera ovisi o spolu.
```

Zadatak 9. Na reprezentativnom uzorku od 180 ljudi iz neke populacije izvršeno je istraživanje kojemu je cilj bio odrediti postoji li povezanost između pušenja i povišenog krvnog tlaka. Rezultati istraživanja prikazani su u sljedećoj tablici:

	nepušač	povremeni pušač	teški pušač	Σ
normalan tlak	48	26	19	93
povišen tlak	21	36	30	87
Σ	69	62	49	180

Testirajte postoji li povezanost na razini značajnosti 0.05.

```
##### Zadatak 9.
#Hipoteze:
# H0: obilježja su nezavisna
# H1: postoji zavisnost
(tf <- matrix(c(48, 26, 19, 21, 36, 30), 2, 3, byrow = TRUE))
chisq.test(tf)
#p = 0.0007232 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i
  prihvaćamo H1,
# tj. možemo tvrditi da postoji povezanost između pušenja i povišenog
  krvnog tlaka
```

```

#Kako možemo uočiti vezu na osnovu tablice frekvencija?
#Možemo promatrati procjene za uvjetne distribucije:
# za tlak:
prop.table(tf, 2)
prop.table(margin.table(tf, 1))
#kod teških pušača je veći udio povišenog tlaka nego kod nepušača, ili kod
  cijele populacije.
# za pušenje:
prop.table(tf, 1)
prop.table(margin.table(tf, 2))
#kod normalnog tlaka je veći udio nepušača nego kod osoba s povišenim
  tlakom.
#Možemo promatrati i opažene i očekivane frekvencije:
tf
chisq.test(tf)$expected

```

Zadatak 10. U paketu BSDA nalazi se baza Politic koja sadrži podatke iz ankete u kojoj su se ispitanici izjašnjavali između tri političke stranke, a zabilježen je njihov spol. Možemo li na razini značajnosti 0.05 tvrditi da odabir političke stranke ovisi o spolu?

```

#### Zadatak 10.
#Hipoteze:
# H0: odabir političke stranke i spol su nezavisna obilježja
# H1: odabir političke stranke i spol nisu nezavisna obilježja
library("BSDA")
str(Politic)
#Tablica frekvencija
(tf <- table(Politic))
chisq.test(tf)
#Warning se ispisuje jer nisu sve očekivane frekvencije veće ili jednake 5
chisq.test(tf)$expected
#Iz tog razloga u ovom konkretnom slučaju treba biti oprezan sa zaključkom
  chi^2 testa.
#Dobivena p-vrijednost je veća od 0.05 pa ne bi odbacili H0, nema dokaza da
  odabir stranke ovisi o spolu.

```