

IV.5. Testovi o očekivanju za vezane slučajne uzorke

Neka su $\mathbf{X}^1 = (X_1^{(1)}, \dots, X_n^{(1)})$ i $\mathbf{X}^2 = (X_1^{(2)}, \dots, X_n^{(2)})$ slučajni uzorci tako da je $((X_1^{(1)}, X_1^{(2)}), \dots, (X_n^{(1)}, X_n^{(2)}))$ dvodimenzionalan j.s.u. Posebno $\mathbf{X}^{(1)}$ i $\mathbf{X}^{(2)}$ su j.s.u., ali ne moraju biti nezavisni. Slučajni vektori $(X_i^{(1)}, X_i^{(2)})$, $i = 1, \dots, n$ su nezavisni i jednako distribuirani. Želimo testirati hipotezu

$$H_0: \mu_1 = \mu_2$$

gdje je $\mu_1 = E X_i^{(1)}$ i $\mu_2 = E X_i^{(2)}$. U tu svrhu promatrat ćemo slučajni vektor razlika

$$D_i = X_i^{(1)} - X_i^{(2)}, i = 1, \dots, n.$$

Kako je $(D_1, \dots, D_n)$ j.s.u. i $\mu_D = \mu_1 - \mu_2$ hipotezu možemo ekvivalentno izraziti kao

$$H_0: \mu_D = 0$$

čime se problem svodi na test o očekivanju na jednom uzorku (razlikama) pa možemo koristiti:

- z -test na jednom uzorku ako je varijanca distribucije razlika poznata, a uzorak je velik ili su razlike normalno distribuirane,
- t -test na jednom uzorku ako je varijanca distribucije razlika nepoznata, a uzorak je velik ili su razlike normalno distribuirane.

Napomene:

- Ako dva uzorka dolaze iz normalne distribucije, njihove razlike ne moraju biti normalno distribuirane (npr. za $X_i^{(1)} = X_i^{(2)}$ – razlika je 0 g.s.). Dakle, uvjet se odnosi na razlike.
- Ukoliko su uzorci različite veličine, test na razlikama se ne može primijeniti. Mogli bi se pitati, zašto ne bi opisani pristup koristili i za nezavisne uzorke ako su oni iste veličine? Jedan razlog je što bi sparivanje podataka u tom slučaju bilo u potpunosti proizvoljno (time možemo značajno utjecati na rezultat testa). Drugi razlog je što je test na dva uzorka jači na nezavisnim uzorcima – ima veću jakost – vjerojatnost odbacivanja H_0 kad je H_1 istinita $(1 - \beta)$.

IV.6. Test o proporciji za vezane slučajne uzorke

Neka je $((X_1^{(1)}, X_1^{(2)}), \dots, (X_n^{(1)}, X_n^{(2)}))$ dvodimenzionalan j.s.u. takav da je $\mathbf{X}^{(1)} = (X_1^{(1)}, \dots, X_n^{(1)})$ j.s.u. iz Bernoullijeve distribucije

$$\begin{pmatrix} 0 & 1 \\ 1 - \theta_1 & \theta_1 \end{pmatrix}$$

i $\mathbf{X}^{(2)} = (X_1^{(2)}, \dots, X_n^{(2)})$ j.s.u. iz Bernoullijeve distribucije

$$\begin{pmatrix} 0 & 1 \\ 1 - \theta_2 & \theta_2 \end{pmatrix}$$

Želimo testirati

$$H_0 : \theta_1 = \theta_2.$$

Označimo zajedničku tablicu frekvencija s

$X^{(1)} \setminus X^{(2)}$	0	1	Σ
0	a	b	$a + b$
1	c	d	$c + d$
Σ	$a + c$	$b + d$	n

Uočimo:

- procjena za $\theta_1 : \frac{c+d}{n}$
- procjena za $\theta_2 : \frac{b+d}{n}$
- procjena za $\theta_1 - \theta_2 : \frac{c+d}{n} - \frac{b+d}{n} = \frac{c-b}{n}$ ne ovisi o a i d koji ne daju informaciju o razlikama proporcija (za zaključivanje će biti bitno samo kada se ishodi razlikuju, a koliko puta su ishodi jednaki je nebitno).

Za zaključivanje o razlici bit će bitni samo parovi $(0, 1)$ i $(1, 0)$ (udio svakog od njih u ne-nul razlikama). Dakle, a i d nisu relevantni za zaključivanje o tome razlikuju li se θ_1 i θ_2 , a mogu pokazati koliko se razlikuju ako se razlikuju. Veliki a i d za fiksne b i c mogu pokazati da su razlike male ako postoje. Distribucije razlika $X_i^{(1)} - X_i^{(2)}$ uz uvjet da je $X_i^{(1)} \neq X_i^{(2)}$

$$\begin{pmatrix} -1 & 1 \\ 1 - \bar{\theta} & \bar{\theta} \end{pmatrix},$$

gdje je

$$\begin{aligned} X_i^{(1)} - X_i^{(2)} = -1 &\iff (X_i^{(1)}, X_i^{(2)}) = (0, 1), \\ X_i^{(1)} - X_i^{(2)} = 1 &\iff (X_i^{(1)}, X_i^{(2)}) = (1, 0), \end{aligned}$$

možemo procijeniti s

$$\begin{pmatrix} -1 & 1 \\ \frac{b}{b+c} & \frac{c}{b+c} \end{pmatrix},$$

gdje je

- $\frac{b}{b+c}$ - relativna frekvencija $(0, 1)$ u ne-nul razlikama
- $\frac{c}{b+c}$ - relativna frekvencija $(1, 0)$ u ne-nul razlikama.

Hipoteze sada možemo ekvivalentno zapisati:

$$H_0 : \theta_1 = \theta_2 \iff H_0 : \bar{\theta} = \frac{1}{2} \text{ (proporcija parova } (0, 1) \text{ je jednaka proporciji parova } (1, 0))$$

$$H_1 : \theta_1 \neq \theta_2 \iff H_1 : \bar{\theta} \neq \frac{1}{2} \text{ (proporcija parova } (0, 1) \text{ nije jednaka proporciji parova } (1, 0))$$

$$H_1 : \theta_1 > \theta_2 \iff H_1 : \bar{\theta} > \frac{1}{2} \text{ (proporcija parova } (0, 1) \text{ je manja od proporcije parova } (1, 0))$$

$$H_1 : \theta_1 < \theta_2 \iff H_1 : \bar{\theta} < \frac{1}{2} \text{ (proporcija parova } (0, 1) \text{ je veća od proporcije parova } (1, 0))$$

U uvjetima istinitosti H_0 , broj pozitivnih razlika (parova $(1, 0)$) među ne-nul razlikama ima $\mathcal{B}(b + c, \frac{1}{2})$ distribuciju. Stoga se test može provesti kao test o proporciji na jednom uzorku - binomni test. Broj uspjeha je c od $b + c$ ponavljanja, a uspoređujemo s parametrom $\frac{1}{2}$.

Test je u literaturi poznat i kao egzaktna verzija McNemarovog testa.

IV.7. χ^2 test o nezavisnosti

Neka je $(X_1, X_2), \dots, (X_N, Y_N)$ dvodimenzionalan j.s.u. iz diskretnog slučajnog vektora (X, Y) , odnosno (X_i, Y_i) , $i = 1, \dots, N$ su nezavisni slučajni vektori, jednako distribuirani kao slučajni vektor (X, Y) . Slučajne varijable X i Y ne moraju biti nezavisne, naprotiv, to je ono što želimo provjeriti. U praktičnom smislu, promatramo dva obilježja na N jedinki i zanima nas zavisnost tih obilježja.

Pretpostavljamo da je distribucija od (X, Y) diskretna s konačnom slikom, a možemo je zapisati tablicom

$X \setminus Y$	y_1	y_2	$\dots$	y_n	
x_1	p_{11}	p_{12}	$\dots$	p_{1n}	p_{x_1}
x_2	p_{21}	p_{22}	$\dots$	p_{2n}	p_{x_2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_m	p_{m1}	p_{m2}	$\dots$	p_{mn}	p_{x_m}
	p_{y_1}	p_{y_2}	$\dots$	p_{y_n}	1

gdje je

- $p_{ij} = P(X = x_i, Y = y_j)$, $i = 1, \dots, m$, $j = 1, \dots, n$
- $p_{x_i} = P(X = x_i) = \sum_{j=1}^n p_{ij}$, $i = 1, \dots, m$
- $p_{y_j} = P(Y = y_j) = \sum_{i=1}^m p_{ij}$, $j = 1, \dots, n$,

a pri čemu su

$$\begin{pmatrix} x_1 & \dots & x_m \\ p_{x_1} & \dots & p_{x_m} \end{pmatrix}, \quad \begin{pmatrix} y_1 & \dots & y_n \\ p_{y_1} & \dots & p_{y_n} \end{pmatrix}$$

marginalne distribucije slučajnog vektora (X, Y) .

Prisjetimo se, slučajne varijable X i Y su nezavisne ako je

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j), \quad \text{za sve } i = 1, \dots, m, \quad j = 1, \dots, n.$$

Uz naše oznake to je

$$p_{ij} = p_{x_i} \cdot p_{y_j}, \quad \text{za sve } i = 1, \dots, m, \quad j = 1, \dots, n.$$

Označimo uvjetnu vjerojatnost za dani $j \in \{1, \dots, n\}$ s

$$p_{x_i|y_j} = P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{y_j}}, \quad i = 1, \dots, m,$$

a za dani $i \in \{1, \dots, m\}$

$$p_{y_j|x_i} = P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)} = \frac{p_{ij}}{p_{x_i}}, \quad j = 1, \dots, n$$

koje definiraju slučajne varijable $X|_{Y=y_j}$ odnosno $Y|_{X=x_i}$.

Uočimo da ako su X i Y nezavisne slučajne varijable, onda je

$$p_{x_i|y_j} = \frac{p_{x_i} \cdot p_{y_j}}{p_{y_j}} = p_{x_i} \quad \text{za } i = 1, \dots, m$$

i

$$p_{y_j|x_i} = \frac{p_{y_j} \cdot p_{x_i}}{p_{x_i}} = p_{y_j} \quad \text{za } j = 1, \dots, n.$$

Dakle, X i Y su nezavisne slučajne varijable ako i samo ako su odgovarajuće uvjetne i marginalne distribucije jednake:

$$\begin{aligned} X|_{Y=y_1} &\stackrel{d}{=} \dots \stackrel{d}{=} X|_{Y=y_n} \stackrel{d}{=} X \\ Y|_{X=x_1} &\stackrel{d}{=} \dots \stackrel{d}{=} Y|_{X=x_m} \stackrel{d}{=} Y \end{aligned}$$

Na osnovu uzorka možemo formirati **zajedničku tablicu frekvencija (kontingencijska tablica)**

$X \backslash Y$	y_1	y_2	$\dots$	y_n	
x_1	f_{11}	f_{12}	$\dots$	f_{1n}	f_{x_1}
x_2	f_{21}	f_{22}	$\dots$	f_{2n}	f_{x_2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_m	f_{m1}	f_{m2}	$\dots$	f_{mn}	f_{x_m}
	f_{y_1}	f_{y_2}	$\dots$	f_{y_n}	N

pri čemu je

- f_{ij} - frekvencija parova (x_i, y_j) u uzorku
- f_{x_i} (f_{y_j}) - frekvencija x_i (y_j)

Prema definiciji, o nezavisnosti X i Y bi mogli zaključiti na osnovu zajedničke distribucije. **Zajedničkom tablicom relativnih frekvencija** možemo procijeniti distribuciju slučajnog vektora (X, Y) (**empirijska distribucija slučajnog vektora**)

$X \backslash Y$	y_1	y_2	$\dots$	y_n	
x_1	$\hat{p}_{11}$	$\hat{p}_{12}$	$\dots$	$\hat{p}_{1n}$	$\hat{p}_{x_1}$
x_2	$\hat{p}_{21}$	$\hat{p}_{22}$	$\dots$	$\hat{p}_{2n}$	$\hat{p}_{x_2}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_m	$\hat{p}_{m1}$	$\hat{p}_{m2}$	$\dots$	$\hat{p}_{mn}$	$\hat{p}_{x_m}$
	$\hat{p}_{y_1}$	$\hat{p}_{y_2}$	$\dots$	$\hat{p}_{y_n}$	1

gdje je

- $\hat{p}_{ij} = \frac{f_{ij}}{N}$ - relativna frekvencija parova (x_i, y_j) u uzorku,
- $\hat{p}_{x_i} = \frac{f_{x_i}}{N}$ - procjena za p_{x_i} ,

- $\hat{p}_{y_j} = \frac{f_{y_j}}{N}$ – procjena za p_{y_j} .

Procjena uvjetnih distribucija: za dani $j \in \{1, \dots, n\}$ $p_{x_i|y_j}$ možemo procijeniti s

$$\hat{p}_{x_i|y_j} = \frac{\hat{p}_{ij}}{\hat{p}_{y_j}} = \frac{\frac{f_{ij}}{N}}{\frac{f_{y_j}}{N}} = \frac{f_{ij}}{f_{y_j}}, i = 1, \dots, m \text{ (udio } (x_i, y_j) \text{ među } y_j \text{ – po stupcima)}$$

i za dani $i \in \{1, \dots, m\}$

$$\hat{p}_{x_i|y_j} = \frac{f_{ij}}{f_{x_i}}, j = 1, \dots, n \text{ (udio } (x_i, y_j) \text{ među } x_i \text{ – po retcima) .}$$

Hipoteze koje želimo testirati su:

$H_0 : p_{ij} = p_{x_i} \cdot p_{y_j}$ za sve $i \in \{1, \dots, m\}$ i $j \in \{1, \dots, n\}$ (X i Y su nezavisne)

$H_1 : \text{postoje } i \in \{1, \dots, m\} \text{ i } j \in \{1, \dots, n\} \text{ takvi da je } p_{ij} \neq p_{x_i} \cdot p_{y_j}$ (X i Y su zavisne)

Ako su X i Y nezavisne, onda u zajedničkoj tablici relativnih frekvencija očekujemo da je $\hat{p}_{ij} \approx \hat{p}_{x_i} \cdot \hat{p}_{y_j}$ za sve $i = 1, \dots, m$ i $j = 1, \dots, n$. Ekvivalentno, očekujemo da procjene uvjetnih distribucija budu približno jednake, tj. da je

$$\hat{p}_{x_i|y_1} \approx \dots \approx \hat{p}_{x_i|y_n} \approx \hat{p}_{x_i}, \text{ za sve } i = 1, \dots, m$$

i

$$\hat{p}_{y_j|x_1} \approx \dots \approx \hat{p}_{y_j|x_n} \approx \hat{p}_{y_j}, \text{ za sve } j = 1, \dots, n.$$

Definiramo test-statistiku:

$$D_{m,n} = \sum_{i=1}^m \sum_{j=1}^n \frac{(f_{ij} - N\hat{p}_{x_i}\hat{p}_{y_j})^2}{N\hat{p}_{x_i}\hat{p}_{y_j}}$$

Uočimo da je u uvjetima istinitosti H_0 , $N\hat{p}_{x_i}\hat{p}_{y_j}$ očekivana frekvencija (x_i, y_j) pa test-statistika ima oblik (opažene – očekivane frekvencije)²/očekivane frekvencije kao kod χ^2 testa o homogenosti i χ^2 testa na jednom uzorku.

U uvjetima istinitosti H_0 , statistika $D_{m,n}$ ima $\chi^2_{(n-1)(m-1)}$ distribuciju. Veće vrijednosti realizacije statistike $D_{m,n}$ idu u prilog alternativnoj hipotezi H_1 , stoga je kritično područje

$$C = [h_\alpha, \infty), h_\alpha = Q_{\chi^2_{(n-1)(m-1)}}(1 - \alpha)$$

i p -vrijednost

$$p = P(\chi^2_{(n-1)(m-1)} \geq \hat{d}_{m,n})$$

za realizaciju test-statistike $\hat{d}_{m,n}$. Test je asimptotski te kao i ranije i ovdje bi očekivane frekvencije trebale biti barem 5.

Napomena: Kod χ^2 -testa o homogenosti test-statistika ima isti oblik, a očekivane frekvencije su definirane kao $\hat{p}_j \cdot n_i$, gdje je $\hat{p}_j$ relativna frekvencija y_j u cijelom uzorku, a n_i veličina i -te populacije. Promatramo li $x_1, \dots, x_n$ kao oznake populacija, tada u tim oznakama $\hat{p}_{y_j}$ ima ulogu $\hat{p}_j$, a $f_{x_i} = \hat{p}_{x_i} \cdot N$ odgovara n_i . Stoga bi očekivane frekvencije bile $\hat{p}_j \cdot n_i = \hat{p}_{y_j} \cdot \hat{p}_{x_i} N$. Prema tome, testovi su potpuno jednaki ali imaju različite hipoteze. Razlika dolazi od dizajna eksperimenta nad kojim se provodi test:

- kod testa o nezavisnosti uzorkovanje se vrši tako da se iz cijele populacije bira uzorak koji se klasificira prema dva diskretna obilježja, pa je i broj realizacija po kategorijama slučajna (npr. za odabrani uzorak učenika bilježimo ocjene iz matematike i fizike – ne znamo unaprijed broj određenih ocjena u uzorku niti za matematiku niti za fiziku),
- kod testa o homogenosti uzorkovanje se vrši nezavisno u m kategorija (populacija) pa su veličine uzoraka po populacijama unaprijed određene (npr. promatramo ocjene iz matematike za 10 učenika s ocjenom 5 iz fizike, za 20 učenika s ocjenom 4 iz fizike itd. – jedna margina je fiksirana).