

IV.8. Mjere asocijacije i korelacije

```
#Pearsonov koeficijent korelacije, te Spearmanov i Kendallov koeficijent
# korelacije ranga možemo dobiti funkcijom cor()
x <- rnorm(100, 0, 1)
y <- rnorm(100, 5, 1)

cor(x, y) #ili cor(x, y, method = "pearson")
cor(x, y, method = "spearman")
cor(x, y, method = "kendall")
# Sve tri vrijednosti su blizu 0 što je za očekivati s obzirom da su uzorci
# nezavisno generirani

# Dijagram raspršenosti:
plot(x, y)

####Primjer:
x <- rnorm(100)
y <- 2*x + 1
plot(x, y)

cor(x, y)
cor(x, y, method = "spearman")
cor(x, y, method = "kendall")
# Deterministička monotona veza i to linearna.

####Primjer: linearna veza s aditivnom greškom
x <- 1:100
y <- -5*x + rnorm(100, 0, 50)
plot(x, y)

cor(x, y)
cor(x, y, method = "spearman")
cor(x, y, method = "kendall")

####Primjer:
x <- rnorm(100)
y <- x^2
plot(x, y)

cor(x, y)
cor(x, y, method = "spearman")
cor(x, y, method = "kendall")
#Iako su x i y deterministički vezani, niti jedna od mjera to nije u
# mogućnosti u potpunosti prepoznati.

####Primjer:
x <- rnorm(100)
```

```

y <- x^3
plot(x, y)

cor(x, y)
cor(x, y, method = "spearman")
cor(x, y, method = "kendall")
#Uočimo razliku između korelacije i postojanja monotone veze

```

Zadatak 1. Tablica **pozar.csv** sadrži podatke o iznosima šteta nastalih požarom i udaljenosti mjesta požara od vatrogasnog centra. Grafički prikazite parove podataka. Ukazuju li mjere asocijacije i korelacije na postojanje zavisnosti? Na razini značajnosti 0.05 odgovorite:

1. Možemo li tvrditi postojanje korelacije?
2. Možemo li tvrditi postojanje pozitivne korelacije?
3. Možemo li tvrditi postojanje monotone veze?
4. Možemo li tvrditi postojanje zavisnosti?

```

##### Zadatak 1.
# X – udaljenost do vatrogasnog centra
# Y – iznos štete od požara
pozar <- read.csv2("pozar.csv")
str(pozar)
attach(pozar)
x <- udaljenost
y <- steta

plot(x, y)

cor(x, y) #Ukazuje na postojanje pozitivne korelacije
cor(x, y, method = "spearman")
cor(x, y, method = "kendall") #Ukazuju na postojanje rastuće monotone veze

## a)
#Hipoteze:
# H0: \rho = 0
# H1: \rho !=0
cor.test(x, y)
#p < 2.2e-16 < 0.05 – odbacujemo H0, postoji korelacija

## b)
#Hipoteze:
# H0: \rho = 0
# H1: \rho > 0
cor.test(x, y, alternative = "greater")
# p < 2.2e-16 < 0.05 – odbacujemo H0, postoji pozitivna korelacija

```

```
## c)
#Možemo testirati jednakost vrijednosti Spearmanovom i Kendallovog
#koeficijenta nuli
#Hipoteze:
# H0: \rho_S = 0
# H1: \rho_S !=0
cor.test(x, y, method = "spearman")
#p < 2.2e-16 < 0.05 – odbacujemo H0, veza je monotona
# Zbog postojanja jednakih vrijednosti koristi se asimptotska verzija testa
.

#Hipoteze:
# H0: \tau = 0
# H1: \tau !=0
cor.test(x, y, method = "kendall")
#p < 2.2e-16 < 0.05 – odbacujemo H0, veza je monotona
# Zbog velične uzorka (>50) koristi se asimptotska verzija testa.

## d)
#Da, svakako zbog (a), (b) i (c).
```

Zadatak 2. U tablici *Animals* iz R paketa *MASS* nalaze se podaci o masi 28 vrsta životinja i masi njihovog mozga. Jesu li masa i masa mozga pozitivno korelirane na razini značajnosti 0.05? Ukazuje li veća masa na veću masu mozga na razini značajnosti 0.05? Odgovorite na ista pitanja za logaritmiranu tjelesnu masu i logaritmiranu masu mozga.

```
##### Zadatak 2.
library("MASS")
str(Animals)
attach(Animals)

plot(body, brain, xlim = c(0, 100000))
text(body, brain, labels = row.names(Animals), pos = 4)

#Testiramo postoji li pozitivna korelacija:
# H0: \rho = 0
# H1: \rho > 0
cor.test(body, brain, alternative = "greater")
# p = 0.5108 > 0.05, nema dokaza da postoji pozitivna korelacija.

#Testiramo postoji li rastuća veza
#Spearmanov koeficijent
# H0: \rho_S = 0
# H1: \rho_S > 0
cor.test(body, brain, method = "spearman", alternative = "greater")
#Kendallov tau
# H0: \tau = 0
# H1: \tau > 0
cor.test(body, brain, method = "kendall", alternative = "greater")
#p < 0.05 pa možemo tvrditi da postoji rastuća veza.
```

```

#Warning upozorava na to da u promatranim uzorcima ima jednakih podataka,
# pa se p-vrijednost određuje
# korištenjem aproksimacije distribucije test-statistike (aproksimacija je
# T distribucija
# za Spearmanov odnosno N(0, 1) za Kendallov koeficijent).

#Za logaritmirane podatke:
plot(log(body), log(brain))
text(log(body), log(brain), labels = row.names(Animals), pos = 4)
#Uočavamo linearnu vezu, izuzmemo li tri dinosaura koji značajno odstupaju.

#Testiramo postoji li pozitivna korelacija:
# H0: \rho = 0
# H1: \rho > 0
cor.test(log(body), log(brain), alternative = "greater")
#p < 0.05, pa možemo tvrditi da postoji pozitivna korelacija.

#Testiramo postoji li rastuća veza
#Spearmanov koeficijent
# H0: \rho_S = 0
# H1: \rho_S > 0
cor.test(log(body), log(brain), method = "spearman", alternative = "greater")
#Kendallov tau
# H0: \tau = 0
# H1: \tau > 0
cor.test(body, brain, method = "kendall", alternative = "greater")
#p < 0.05 pa možemo tvrditi da postoji rastuća veza.

```

Zadatak 3. U R tablici *mtcars* nalaze se tehnički podaci za 32 automobila. Utvrdite postoji li korelacija i monotona veza između potrošnje goriva (*mpg*) i snage automobila (*hp*)? Je li veza rastuća ili padajuća? Isto učinite za potrošnju goriva i masu automobila (*wt*).

```

#### Zadatak 3.
str(mtcars)
attach(mtcars)
plot(mpg, hp)
#Testiramo postoji li korelacija:
# H0: \rho = 0
# H1: \rho != 0
cor.test(mpg, hp)
#p < 0.05, pa možemo tvrditi da postoji korelacija.
#Testiramo postoji li monotona veza
#Spearmanov koeficijent
# H0: \rho_S = 0
# H1: \rho_S != 0
cor.test(mpg, hp, method = "spearman")
#Kendallov tau

```

```
# H0: \tau = 0
# H1: \tau != 0
cor.test(mpg, hp, method = "kendall")
#p < 0.05 pa možemo tvrditi da postoji monotona veza.
# Po vrijednostima koeficijenata je padajuća (radi se o potrošnji goriva u
  miljama po galonu).

plot(mpg, wt)
#Testiramo postoji li korelacija:
# H0: \rho = 0
# H1: \rho != 0
cor.test(mpg, wt)
#p < 0.05 pa možemo tvrditi da postoji korelacija.
#Testiramo postoji li monotona veza
#Spearmanov koeficijent
# H0: \rho_S = 0
# H1: \rho_S != 0
cor.test(mpg, wt, method = "spearman")
#Kendallov tau
# H0: \tau = 0
# H1: \tau != 0
cor.test(mpg, wt, method = "kendall")
#p < 0.05 pa možemo tvrditi da postoji monotona veza.
# Po vrijednostima koeficijenata je padajuća.
```