

IV.8. Mjere asocijacije i korelacije

Asocijacija i korelacija predstavljaju veze između slučajnih varijabli koje ih čine zavisnima. Značajnost i jakost tih veza možemo iskazati različitim mjerama.

1. Pearsonov koeficijent korelacije

Neka je (X, Y) slučajan vektor takav da je $E X^2 < \infty$ i $E Y^2 < \infty$. **Koeficijent korelacije** vektora (X, Y) je

$$\rho_{XY} = \frac{E[(X - E X)(Y - E Y)]}{\sqrt{\text{Var } X \text{Var } Y}}$$

Vrijedi sljedeće:

- $\rho_{XY} \in [-1, 1]$,
- ako su X i Y nezavisne, onda je $\rho_{XY} = 0$ (obrat općenito ne vrijedi)
- $Y = aX + b$ za $a > 0, b \in \mathbb{R} \iff \rho_{XY} = 1$,
- $Y = aX + b$ za $a < 0, b \in \mathbb{R} \iff \rho_{XY} = -1$.

Kažemo da su X i Y **nekorelirane** ako je $\rho_{XY} = 0$. Nekoreliranost općenito ne povlači nezavisnost (to vrijedi primjerice ako je (X, Y) normalan slučajan vektor). Prema tome, zavisnost slučajnih varijabli X i Y možemo potvrditi ako pokažemo da je $\rho_{XY} \neq 0$. S druge strane, ako je $\rho_{XY} = 1$ ($\rho_{XY} = -1$) veza između X i Y je rastuća (padajuća) linearna veza. Koeficijent korelacije možemo procijeniti s nekoliko procjenitelja od kojih detaljnije opisujemo samo jedan.

Neka je $(x_1, y_1), \dots, (x_n, y_n)$ realizacija j.s.u. iz slučajnog vektora (X, Y) . **Pearsonov koeficijent korelacije** definiramo izrazom

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)}{\sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y}_n)^2}}.$$

Da bismo na osnovu uzorka potvrdili zavisnost korištenjem koeficijenta korelacije, treba odbaciti hipotezu:

$$H_0 : \rho_{XY} = 0.$$

Pretpostavimo da (X, Y) dolazi iz dvodimenzionalne normalne distribucije. Realizacija test-statistike za testiranje prethodne hipoteze dana je izrazom:

$$\hat{t} = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}.$$

U uvjetima istinitosti H_0 , test-statistika čija je realizacija $\hat{t}$ ima $\mathcal{T}_{n-2}$ distribuciju. Ako je T slučajna varijabla takva da $T \sim \mathcal{T}_{n-2}$, p -vrijednost testa određujemo na uobičajen način:

$$\begin{array}{lll} H_1 : \rho_{XY} \neq 0 & H_1 : \rho_{XY} > 0 & H_1 : \rho_{XY} < 0 \\ p = 2P(T \geq |\hat{t}|) & p = P(T \geq \hat{t}) & p = P(T \leq \hat{t}) \end{array}$$

Test se može koristiti i bez pretpostavke normalnosti ako je uzorak velik i ako odstupanje od normalnosti nije preveliko (primjerice, distribucije nisu jako asimetrične).

2. Spearmanov koeficijent korelacije rangova

Spearmanov koeficijent korelacije rangova $\rho_S \in [-1, 1]$ pokazuje u kojoj mjeri se veza između dvije slučajne varijable X i Y može opisati monotonom funkcijom na način da vrijedi:

- $\rho_S = 0$ – ne postoji monotona veza između X i Y ,
- $\rho_S > 0$ – veza između X i Y je rastuća,
- $\rho_S < 0$ – veza između X i Y je padajuća.

Neka je $(x_1, y_1), \dots, (x_n, y_n)$ realizacija j.s.u. iz slučajnog vektora (X, Y) . Spearmanov koeficijent temelji se na **rangovima** podataka. Rang nekog podatka je njegov redni broj u sortiranom nizu. Primjerice, rang podatka 4 u nizu 2, 5, 6, 4 je jednak 2 jer je u sortiranom nizu 2, 4, 5, 6 podatak 4 na poziciji 2. Označimo:

- r_{x_i} rang podatka x_i u sortiranom nizu podataka $(x_1, \dots, x_n)$
- r_{y_i} rang podatka y_i u sortiranom nizu podataka $(y_1, \dots, y_n)$.

Tada ρ_S možemo procijeniti s

$$r_S = 1 - \frac{6 \sum_{i=1}^n (r_{x_i} - r_{y_i})^2}{n(n^2 - 1)}.$$

Pretpostavimo radi jednostavnosti da su svi $x_1, \dots, x_n$ i $y_1, \dots, y_n$ različiti. Uočimo da je:

$$\begin{aligned} \bar{r}_x &= \frac{1}{n} \sum_{i=1}^n r_{x_i} = \frac{1}{n} \frac{n(n+1)}{2} = \frac{n+1}{2} \\ \sum_{i=1}^n (r_{x_i} - \bar{r}_x)^2 &= \sum_{i=1}^n r_{x_i}^2 - 2\bar{r}_x \sum_{i=1}^n r_{x_i} + n(\bar{r}_x)^2 = \sum_{i=1}^n r_{x_i}^2 - n\bar{r}_x^2 \\ &= \frac{n(n+1)(2n+1)}{6} - \frac{n(n+1)^2}{4} = \frac{n(n^2-1)}{12} \end{aligned}$$

te isto vrijedi i za $\bar{r}_y$ i $\sum_{i=1}^n (r_{y_i} - \bar{r}_y)^2$.

Sada r_S možemo napisati kao:

$$\begin{aligned}
 r_S &= \frac{12}{n(n^2-1)} \left(\frac{n(n^2-1)}{12} - \frac{1}{2} \left(\sum_{i=1}^n r_{x_i}^2 - 2 \sum_{i=1}^n r_{x_i} r_{y_i} + \sum_{i=1}^n r_{y_i}^2 \right) \right) \\
 &= \frac{12}{n(n^2-1)} \left(\sum_{i=1}^n r_{x_i} r_{y_i} - \frac{n(n+1)(2n+1)}{6} + \frac{n(n+1)(n-1)}{12} \right) \\
 &= \frac{12}{n(n^2-1)} \left(\sum_{i=1}^n r_{x_i} r_{y_i} - \frac{n(n+1)^2}{4} \right) \\
 &= \frac{12}{n(n^2-1)} \left(\sum_{i=1}^n r_{x_i} r_{y_i} - \frac{(n+1)n(n+1)}{2} - \frac{(n+1)n(n+1)}{2} + n \left(\frac{n+1}{2} \right)^2 \right) \\
 &= \frac{12}{n(n^2-1)} \left(\sum_{i=1}^n r_{x_i} r_{y_i} - \bar{r}_y \sum_{i=1}^n r_{x_i} - \bar{r}_x \sum_{i=1}^n r_{y_i} + \sum_{i=1}^n \bar{r}_x \bar{r}_y \right) \\
 &= \frac{\sum_{i=1}^n (r_{x_i} - \bar{r}_x)(r_{y_i} - \bar{r}_y)}{\sqrt{\sum_{i=1}^n (r_{x_i} - \bar{r}_x)^2} \sqrt{\sum_{i=1}^n (r_{y_i} - \bar{r}_y)^2}}
 \end{aligned}$$

Time smo pokazali da je Spearmanov koeficijent zapravo Pearsonov koeficijent korelacije, ali ne podataka, nego rangova podataka.

Za testiranje hipoteze

$$H_0 : \rho_S = 0 \quad (\text{ne postoji monotona veza})$$

može se koristiti pristup temeljen na egzaktnoj distribuciji od ρ_S u H_0 ako uzorak nije prevelik (do 1000 u R-u) i ako među podacima $(x_1, \dots, x_n)$ te $(y_1, \dots, y_n)$ ne postoje jednaki. U suprotnom, koristi se asimptotski test za koji je realizacija test statistike

$$\hat{t} = \frac{r_S \sqrt{n-2}}{\sqrt{1-r_S^2}}$$

što odgovara strukturi test statistike kod Pearsonovog koeficijenta korelacije.

Distribucija test statistike u uvjetima istinitosti H_0 može se aproksimirati $\mathcal{T}_{n-2}$ distribucijom za velike uzorke (dovoljno $n > 10$). Alternativna hipoteza može biti jednostrana ili dvostrana:

$$H_1 : \rho_S \neq 0 \quad H_1 : \rho_S > 0 \quad H_1 : \rho_S < 0.$$

3. Kendallov koeficijent korelacije rangova

Kendallov koeficijent korelacije rangova $\tau \in [-1, 1]$ daje informaciju o postojanju monotone veze između slučajnih varijabli X i Y na isti način kao i Spearmanov koeficijent.

Neka je $(x_1, y_1), \dots, (x_n, y_n)$ realizacija j.s.u. iz slučajnog vektora (X, Y) . Pretpostavimo da je $x_i \neq x_j$ i $y_i \neq y_j$ za $i \neq j$ (odgovarajuće procjene za τ postoje i u ostalim slučajevima).

Kažemo da je par podataka (x_i, y_i) i (x_j, y_j) , $i \neq j$ **usklađen** (eng. *concordant*) ako vrijedi jedan od sljedeća dva uvjeta:

- $x_i < x_j$ i $y_i < y_j$
- $x_i > x_j$ i $y_i > y_j$.

U suprotnom kažemo da je par podataka **neusklađen** (eng. *discordant*) (npr. $x_i < x_j$ i $y_i > y_j$). Mogućih parova ima $\binom{n}{2} = \frac{n(n-1)}{2}$. Ako sa n_U označimo broj usklađenih parova, a sa n_N broj neusklađenih, tada je procjena za τ :

$$r_K = \frac{n_U - n_N}{\frac{1}{2}n(n-1)}.$$

Uočimo da je $r_K \in [-1, 1]$. Ako su svi parovi usklađeni $r_K = 1$, a ako su svi neusklađeni $r_K = -1$.

Za testiranje hipoteze

$$H_0 : \tau = 0 \quad (\text{ne postoji monotona veza})$$

može se koristiti test statistika s egzaktnom distribucijom ako uzorak nije prevelik (do 50 u R-u) i nema pojave istih vrijednosti. U suprotnom, koristi se asimptotski test za koji je realizacije test-statistike

$$\hat{z} = \frac{r_K}{\sqrt{\frac{9n(n-1)}{2(2n+5)}}},$$

a distribucija test statistike u uvjetima H_0 može se aproksimirati $\mathcal{N}(0, 1)$ distribucijom. Alternativne hipoteze mogu se postaviti analogno kao kod Spearmanovog koeficijenta.