

IV.9. Jednostavna linearna regresija

```
#Osnovne pojmove promotrimo na simuliranim podacima:
x <- seq(0.1, 10, 0.1)
y <- 2*x + 1 + rnorm(100)
plot(x, y)

#Za procjenu parametara modela koristimo funkciju lm() (linear model)
#Prvi argument funkcije je tzv. R formula modela u kojoj se  $y \sim x$  označava
veza, npr.  $y \sim x$ 
model <- lm(y ~ x)
model

#Ispis ne sadrži puno informaciju osim procijenjenog regresijskog pravca.
#Ostalim rezultatima pristupamo posebno:
summary(model)

coef(model)      #vektor koeficijenata
residuals(model) #vektor reziduala ( $e_i$ )
fitted(model)    #predikcije (teorijske vrijednost  $\hat{y}$ )

#Rezultatima možemo pristupati i na sljedeći način:
names(model)
model$coefficients
model$residuals

#Za dodavanje regresijskog pravca na dijagram raspršenosti dovoljno je
pozvati abline() na modelu
plot(x, y)
abline(model)

#####
#           Analiza kvalitete modela           #

#Dobiveni regresijski pravac može biti porpilično besmislen rezultat, zato
je važno analizirati kvalitetu modela
#Primjer – Anscombe podaci:
str(anscombe)
attach(anscombe)

am1 <- lm(y1 ~ x1)
am2 <- lm(y2 ~ x2)
am3 <- lm(y3 ~ x3)
am4 <- lm(y4 ~ x4)

par(mfrow = c(2, 2))
plot(x1, y1, xlim = c(4, 20), ylim = c(3, 14), main = "Skup podataka 1")
```

```
abline(am1)
plot(x2, y2, xlim = c(4, 20), ylim = c(3, 14), main = "Skup podataka 2")
abline(am2)
plot(x3, y3, xlim = c(4, 20), ylim = c(3, 14), main = "Skup podataka 3")
abline(am3)
plot(x4, y4, xlim = c(4, 20), ylim = c(3, 14), main = "Skup podataka 4")
abline(am4)
dev.off()

summary(am1)
summary(am2)
summary(am3)
summary(am4)

#Iako je u sva četiri primjera regresijski pravac isti, samo prvi model bi
    imao smisla.

#ANALIZA REZIDUALA:

###1. valjanost linearne veze:
plot(x, y)
abline(model)
#Linearna veza ima smisla. Graf reziduala u ovisnosti o nezavisnoj
    varijabli:
plot(x, model$residuals)
#Raspršeno, bez očigledne pravilnosti.
#Za Anscombe skup 2 postoji jasni kvadratni uzorak:
plot(x2, am2$residuals)
#Anscombe skup 3 ukazuje na postojanje stršeće vrijednosti:
plot(x3, am3$residuals)

###2. nezavisnost grešaka:
#Već smo zaključili da u
plot(x, model$residuals)
#ne postoji struktura.
(ei <- model$residuals)
(ei1 <- c(NA, head(ei, -1)))
plot(ei, ei1)
#ili
(ei <- model$residuals[2:length(model$residuals)])
(ei1 <- model$residuals[1:length(model$residuals)-1])
plot(ei, ei1)
#Ne uočavamo postojanje pravilnosti.
#možemo promatrati i na koraku dva (ei, ei2)
(ei <- model$residuals)
(ei2 <- c(NA, NA, head(ei, -2)))
plot(ei, ei2)
#Isti zaključak.
#Reziduali se mogu prije prikaza sortirati po nezavisnoj varijabli ako
    sumnjamo da u tom poretu postoji zavisnost.
#Ovdje su tako generirani, ali inače to možemo napraviti ovako:
order(x)      #order(x) daje vektor indeksa elemenata u rastućem
```

```

redoslijedu (npr. x[order(x)] je sortirani niz)
(ei <- model$residuals[order(x)])
(ei1 <- c(NA, head(ei, -1)))
plot(ei, ei1)
#Na osnovu promatranog, nema dokaza da greške nisu nezavisne.

###3. homogenost varijanci grešaka:
plot(fitted(model), residuals(model))
#Nema sustavnog povećanja ili smanjenja, nema razloga sumnjati u
promjenjivu varijancu.

###4. normalna distribuiranost grešaka:
qqnorm(model$residuals)
qqline(model$residuals)
plot(density(model$residuals))
shapiro.test(model$residuals)
#Nema razloga sumnjati u normalnu distribuiranost.

#ANALIZA ADEKVATNOSTI MODELA:
#Testiramo: H0 a=0
summary(model)
#p< 2e-16 – p-vrijednost je iskazana u tablici koeficijenata.
#Možemo tvrditi da je a značajno različit od 0.

#ANALIZA JAKOSTI MODELA:
summary(model)
#R^2=0.9652 (Multiple R-squared) ukazuje da model odlično opisuje podatke.

```

Zadatak 1. U tablici **proizvodnja.csv** nalaze se podaci o potrebnom vremenu za proizvodnju različitih količina nekog proizvoda. Procijenite parametre linearnog veze između potrebnog vremena i količine proizvoda te zapišite formulu modela. Analizirajte kvalitetu dobivenog modela. Na osnovu dobivenog modela procijenite:

- Koliko vremena treba za proizvodnju jednog dodatnog proizvoda?
- Koliko vremena treba da bi se pokrenula proizvodnja?

```

#### Zadatak 1.
proizvodnja <- read.csv2("proizvodnja.csv")
str(proizvodnja)
attach(proizvodnja)

#Količina je nezavisna varijabla, a potrebno vrijeme zavisna varijabla.
plot(kolicina, vrijeme, xlab = "Broj proizvedenih proizvoda", ylab = "
  Vrijeme trajanja proizvodnje")

m <- lm(vrijeme ~ kolicina)
m
summary(m)

```

```
plot(kolicina, vrijeme, xlab = "Broj proizvedenih proizvoda", ylab = "
  Vrijeme trajanja proizvodnje")
abline(m)
#Formula modela:
# vrijeme = 0.259 kolicina + 149.748

#ANALIZA REZIDUALA:
###1. valjanost linearne veze:
plot(kolicina, vrijeme)
abline(m)
#Linearna veza ima smisla. Graf reziduala u ovisnosti o nezavisnoj
  varijabli:
plot(kolicina, m$residuals)
#Raspršeno, bez očigledne pravilnosti.

###2. nezavisnost grešaka:
#Već smo zaključili da u
plot(kolicina, m$residuals)
#ne postoji struktura.
(ei <- m$residuals)
(ei1 <- c(NA, head(ei, -1)))
plot(ei, ei1)
#Ne uočavamo postojanje pravilnosti.
#Ako sortiramo reziduale po nezavisnoj varijabli
order(kolicina)
(ei <- m$residuals[order(kolicina)])
(ei1 <- c(NA, head(ei, -1)))
plot(ei, ei1)
#Isti zaključak.
#Na osnovu promatranog, nema dokaza da greške nisu nezavisne.

###3. homogenost varijanci grešaka:
plot(fitted(m), residuals(m))
#Nema sustavnog povećanja ili smanjenja, nema razloga sumnjati u
  promjenjivu varijancu.

###4. normalna distribuiranost grešaka:
qqnorm(m$residuals)
qqline(m$residuals)
plot(density(m$residuals))
shapiro.test(m$residuals)
#Nema razloga sumnjati u normalnu distribuiranost.

#ANALIZA ADEKVATNOSTI MODELA:
#Testiramo: H0 a=0
summary(m)
#p=1.61e-06 – p-vrijednost je iskazana u tablici koeficijenata.
#Možemo tvrditi da je a značajno različit od 0.

#ANALIZA JAKOSTI MODELA:
summary(m)
#R^2=0.7302 (Multiple R-squared) ukazuje da model dobro opisuje podatke.
```

```
#(a) Proizvodnja jednog dodatnog proizvoda povećava vrijeme proizvodnje za
      0.259
#(b) Da bi se pokrenula proizvodnja potrebno je 149.748 sati
```

Zadatak 2. Za podatke u tablici **pozar.csv** napravite linearni model za iznose šteta od požara u ovisnosti o udaljenosti od vatrogasnog centra u kilometrima. Prema dobivenom modelu, koliko će se povećati šteta svakim dodatnim kilometrom udaljenosti? Provjerite imamo li razloga sumnjati u valjanost dobivenog modela.

```
#### Zadatak 2.
pozar <- read.csv2("pozar.csv")
str(poazar)
attach(poazar)

#Udaljenost je nezavisna varijabla, a nastala šteta zavisna varijabla.
plot(udaljenost, steta)

m <- lm(steta ~ udaljenost)
m
summary(m)

plot(udaljenost, steta)
abline(m)
#Formula modela:
# steta = 2.022 udaljenost + 4.928
#svaki dodatni kilometar povećava štetu za 2.022

#ANALIZA REZIDUALA:
###1. valjanost linearne veze:
plot(udaljenost, steta)
abline(m)
#Linearna veza ima smisla. Graf reziduala u ovisnosti o nezavisnoj
  varijabli:
plot(udaljenost, m$residuals)
#Raspršeno, bez očigledne pravilnosti.

###2. nezavisnost grešaka:
#Već smo zaključili da u
plot(udaljenost, m$residuals)
#ne postoji struktura.
(ei <- m$residuals)
(ei1 <- c(NA, head(ei, -1)))
plot(ei, ei1)
#Uočavamo postojanje rastuće veze!
plot(ei, ei1)
abline(lm(ei1 ~ ei))
#To ukazuje da su pretpostavke narušene i model ne treba razmatrati ako
  relevantan,
# iako su drugi pokazatelji vrlo dobri (npr. visok R^2).
```

```
#Možemo čak i tvrditi postojanje korelacije u susjednim greškama:
cor.test(ei, ei1)
```

Zadatak 3. *Tablica `ciscenje.csv` sadrži podatke o broju soba koje različiti broj osoblja očisti u nekom hotelu. Napravite odgovarajući linearni model. Prema modelu, koliko soba očisti svaka dodatna osoba? Provjerite imamo li razloga sumnjati u valjanost dobivenog modela.*

```
#### Zadatak 3.
ciscenje <- read.csv2("ciscenje.csv")
str(ciscenje)
attach(ciscenje)

#Broj osoblja je nezavisna varijabla, a broj očišćenih soba je zavisna
  varijabla.
plot(osoblje, sobe)

m <- lm(sobe ~ osoblje)
m
summary(m)

plot(osoblje, sobe)
abline(m)
#Formula modela:
# sobe = 3.701 osoblje + 1.785
#Svaka dodatna osoba očisti 3.701 soba

#ANALIZA REZIDUALA:
###1. valjanost linearne veze:
plot(osoblje, sobe)
abline(m)
#Linearna veza ima smisla. Graf reziduala u ovisnosti o nezavisnoj
  varijabli:
plot(osoblje, m$residuals)
#Raspršeno, bez očigledne pravilnosti osim što se uočava diskretnost
  nezavisne varijable.

###2. nezavisnost grešaka:
#Već smo zaključili da u
plot(osoblje, m$residuals)
#ne postoji struktura.
(ei <- m$residuals)
(ei1 <- c(NA, head(ei, -1)))
plot(ei, ei1)
#Nema jasne pravilnosti.
#Na osnovu promatranog, nema dokaza da greške nisu nezavisne.

###3. homogenost varijanci grešaka:
plot(fitted(m), residuals(m))
#Uočavamo sustavno povećanja raspršenosti – dolazi do promjene varijance.
```

```
#Možemo to objasniti tako što je rezultat rada više osoba varijabilniji  
    nego kada manje osoba obavlja svoj posao.  
#Narušene su osnovne pretpostavke modela.
```

Zadatak 4. U R paketu *mosaic* nalazi se tablica *CPS85* koja sadrži neke podatke za uzorak stanovnika SAD-a (za objašnjenje varijabli pogledati *R help*).

- (a) Analizirajte linearni model plaće po satu (*wage*) u odnosu na broj godina obrazovanja (*educ*). Za koliko svaka godina obrazovanja povećava plaću? Provjerite jesu li koeficijenti statistički značajno različiti od 0 te pretpostavku homogenosti varijance.
- (b) Analizirajte linearni model plaće po satu (*wage*) u odnosu na broj godina iskustva (*exper*). Promotrite jakost modela i značajnost koeficijenata.

```
#### Zadatak 4.  
library("mosaic")  
str(CPS85)  
attach(CPS85)  
  
#(a)  
m1 <- lm(wage ~ educ)  
summary(m1)  
  
plot(educ, wage)  
abline(m1)  
#Svaka godina iskustva povećava plaću za 0.75$ po satu.  
  
#homogenost varijanci  
plot(fitted(m), residuals(m))  
#očigledno varijanca raste  
#Model nije valjan.  
  
#(b)  
m2 <- lm(wage ~ exper)  
summary(m2)  
  
plot(educ, wage)  
abline(m2)  
#na razini značajnosti 0.01 koeficijent smjera nije značajno različit od 0.  
#R^2 iznimno mali što ukazuje na vrlo slabu vezu među varijablama.
```