

IV.9. Regresija

Regresijska¹ analiza je metoda istraživanja funkcijskih veza između varijabli. Ograničit ćemo se na proučavanje veza između dvije varijable i to posebno linearne veze.

Pretpostavimo da raspolažemo podacima $(x_1, y_1), \dots, (x_n, y_n)$. Vrijednosti $x_1, \dots, x_n$ nazivamo vrijednostima **nezavisne varijable** (prediktor ili egzogena varijabla) dok su $y_1, \dots, y_n$ vrijednosti **zavisne varijable** (endogena varijabla ili *response*).

$(y_1, \dots, y_n)$ smatramo realizacijama slučajnog vektora $(Y_1, \dots, Y_n)$ čije su komponente nezavisne ali ne moraju biti jednako distribuirane. Naprotiv, pretpostavljamo da distribucija od Y_i ovisi o x_i tako da je

$$Y_i = f(x_i) + \varepsilon_i, \quad i = 1, \dots, n. \quad (1)$$

$\varepsilon_1, \dots, \varepsilon_n$ su slučajne varijable takve da je $E\varepsilon_i = 0$, $i = 1, \dots, n$, koje nazivamo **greške**, a postoje zbog slučajne prirode promatranog problema (Y_i nije deterministička funkcija od x_i). Klasične pretpostavke na niz $\varepsilon_1, \dots, \varepsilon_n$:

(ε 1) nezavisne,

(ε 2) $\text{Var } \varepsilon_i = \sigma^2$, $i = 1, \dots, n$,

(ε 3) ε_i ima normalnu distribuciju za svaki i .

Jednadžbu (1) nazivamo **regresijski model**. Pretpostavke na greške nam omogućavaju statističko zaključivanje o modelu. Oblik funkcije f pretpostavlja se modelom i to obično tako da se f može izabrati iz neke parametarske klase funkcija (npr. polinom, eksponencijalna funkcija $x \mapsto ae^{bx}$). Prikladan oblik od f može se naslutiti iz dijagrama raspršenosti ili dolazi iz neke teorijske pretpostavke vezane uz problem.

Napomena: Ovisno o prirodi problema i $x_1, \dots, x_n$ se mogu smatrati realizacijom j.s.u. iz slučajne varijable X . U tom slučaju, regresijski model shvaćamo kao:

$$E[Y_i | X = x_i] = f(x_i).$$

Svi rezultati koje ćemo navesti jednako vrijede i u slučaju kada je prediktor slučajna varijabla.

1. Jednostavna linearna regresija

Ako u regresijskom modelu odaberemo $f(x) = ax + b$ linearnu funkciju, dobivamo model **jednostavne linearne regresije**

$$Y_i = ax_i + b + \varepsilon_i, \quad i = 1, \dots, n,$$

¹Dolazi od *regresija prema prosjeku* – Francis Galton je proučavao visinu djece iznad prosjeka kao funkciju visine roditelja iznad prosjeka (djeca viših roditelja ne budu jako visoka pa ponovno uzorkovanje vraća visine u prosjek).

pri čemu je $E\varepsilon_i = 0$, $i = 1, \dots, n$, i vrijedi $(\varepsilon_1) - (\varepsilon_2)$.

Traženje veze između zavisne i nezavisne varijable sada se svodi na procjenu dva nepoznata parametra:

- a – koeficijent smjera (nagib - eng. *slope*) ($a > 0$ rastuća veza, $a < 0$ padajuća veza),
- b – slobodni član (eng. *intercept*).

Metoda najmanjih kvadrata je standardna metoda procjene parametara a i b . Procjene $\hat{a}$ i $\hat{b}$ određuju se tako da suma kvadrata odstupanja opaženih i predviđenih vrijednosti bude minimalna:

$$S(a, b) = \sum_{i=1}^n (y_i - ax_i - b)^2$$

$$S(\hat{a}, \hat{b}) = \min_{(a,b) \in \mathbb{R}^2} S(a, b)$$

Označimo:

$$s_x^2 = \sum_{i=1}^n (x_i - \bar{x}_n)^2, \quad s_y^2 = \sum_{i=1}^n (y_i - \bar{y}_n)^2$$

$$s_{xy} = \sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)$$


Zadatak 1. Pokažite da je procjena parametara (a, b) u modelu jednostavne linearne regresije metodom najmanjih kvadrata dana s

$$\hat{a} = \frac{s_{xy}}{s_x^2}, \quad \hat{b} = \bar{y}_n - \hat{a}\bar{x}_n.$$

Pravac $y = \hat{a}x + \hat{b}$ nazivamo **procjena regresijskog pravca**.

- $\hat{y}_i = \hat{a}x_i + \hat{b}$ nazivamo teorijska vrijednost ili **predikcija**,
- $e_i = y_i - \hat{y}_i$, $i = 1 \dots, n$ nazivamo **reziduali**,
- $SSE = S(\hat{a}, \hat{b}) = \sum_{i=1}^n e_i^2$ nazivamo **suma kvadrata reziduala** (eng. *sum of squared errors*).

Primjer jednog regresijskog pravca prikazan je na sljedećoj slici.



Za procjenitelje $\hat{a}$ i $\hat{b}$ vrijede sljedeća svojstva:

- $\hat{a}$ i $\hat{b}$ su nepristrani procjenitelji za a i b ($E\hat{a} = a$, $E\hat{b} = b$),
- $\text{Var}(\hat{a}) = \frac{\sigma^2}{s_x^2}$, $\text{Var}(\hat{b}) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}_n^2}{s_x^2} \right)$,
- Ako dodatno vrijedi i $(\varepsilon 3)$, $\hat{a}$ i $\hat{b}$ imaju normalnu distribuciju. U suprotnom asimptotski normalnu.
- $s^2 = \frac{1}{n-2}SSE$ je nepristran procjenitelj za σ^2 .

1.1. Analiza kvalitete modela

Obuhvaća tri koraka nakon kojih se donosi odluka o korisnosti i valjanosti modela.

1. Analiza reziduala

Da bi model bio valjan treba provjeriti da ne postoji značajno odstupanje od pretpostavki modela (prvenstveno $(\varepsilon 1)$ i $(\varepsilon 2)$). Reziduali $e_i = y_i - \hat{y}_i$, $i = 1, \dots, n$, su razlike opaženih i predviđenih vrijednosti, stoga ako je model dobro specificiran, rezidualne možemo shvatiti kao opažene greške modela (postoje neke bitne razlike, npr. reziduali nisu nezavisni, ali to rijetko dolazi do izražaja).

Pitanje koje postavljamo je: pokazuju li reziduali da su pretpostavke narušene? Pri tome odgovor *ne* ne znači da su pretpostavke ispunjene već samo da nema razloga sumnjati da nisu ispunjene (slično kao kod testiranja hipoteza).

- valjanost linearne veze – lako se uočava iz dijagrama raspršenosti, a graf točaka (x_i, e_i) , $i = 1, \dots, n$, može ukazivati na druge tipove veza ako u njemu možemo prepoznati uzorak. Ovaj graf može ukazati i na postojanje stršećih vrijednosti (outliera).
- nezavisnost grešaka – graf parova (x_i, e_i) ne smije imati strukturu i treba biti raspršen
 - graf parova (e_i, e_{i-1}) , $i = 1, \dots, n$ i graf parova (e_i, e_{i-2}) , $i = 1, \dots, n$ mogu ukazivati na postojanje korelacije, pa onda i zavisnosti među rezidualima (pri tome e_i trebaju prvo biti sortirani u poretku u kojem sumnjamo na zavisnost (npr. u vremenu, s obzirom na vrijednosti x) ili u poretku podataka ako nemamo slutnju o strukturi zavisnosti).
- homogenost varijanci grešaka – graf parova $(\hat{y}_i, e_i)$, $i = 1, \dots, n$ treba biti jednoliko raspršen bez sustavnog povećanja ili smanjenja.
- normalna distribucija grešaka – standardno analiziramo normalnu distribuiranost niza e_i , $i = 1, \dots, n$ (Q-Q graf, Shapiro-Wilk test). Ovo nije nužan uvjet, ali ako nije ispunjen statističko zaključivanje o modelu temelji se na asimptotskim testovima.

2. Analiza adekvatnosti modela

O adekvatnosti modela zaključujemo na osnovu testiranja hipoteze je li koeficijent smjera $a \neq 0$, odnosno je li dobiveni model bolji od nul-modela $a = 0$ u kojem promjena x ne mijenja y . Za testiranje

$$H_0 : a = 0,$$

$$H_1 : a \neq 0,$$

koristimo test-statistiku

$$T = \frac{s_x \hat{a}}{s} \sim^{H_0} t_{n-2} \quad (\text{vrijedi asimptotski ako } (\varepsilon 3) \text{ ne vrijedi}),$$

a zaključivanje provodimo standardno.

3. Analiza jakosti modela

Iz $e_i = y_i - \hat{y}_i$ slijedi

$$y_i = \hat{y}_i + e_i, \quad i = 1, \dots, n$$

(opažene vrijednosti = vrijednosti iz modela + reziduali)

Uspoređujemo raspršenost ta tri skupa vrijednosti. Može se pokazati da je:

$$\begin{aligned} SSE &= \sum_{i=1}^n (y_i - \hat{a}x_i - \hat{b})^2 = s_y^2 - \hat{a}^2 s_x^2 \\ \Rightarrow s_y^2 &= \hat{a}^2 s_x^2 + SSE \\ \Rightarrow 1 &= \frac{\hat{a}^2 s_x^2}{s_y^2} + \frac{SSE}{s_y^2} \end{aligned}$$

pri čemu izraze u prethodnim jednakostima shvaćamo na sljedeći način:

- $\hat{a}^2 s_x^2$ – rasipanje objašnjeno modelom,
- $\frac{\hat{a}^2 s_x^2}{s_y^2}$ – udio rasipanja objašnjen modelom,
- $\frac{SSE}{s_y^2}$ – udio koji se odnosi na rezidualne (neobjašnjene).

Udio varijabilnosti objašnjen modelom zovemo **koeficijent determinacije R^2** :

$$R^2 = \frac{\hat{a}^2 s_x^2}{s_y^2} \in [0, 1]$$

za koji je poželjno da je što bliži broju jedan.

Uočimo da je

$$\hat{a}^2 = \frac{s_{xy}^2}{s_x^4} \Rightarrow R^2 = \frac{s_{xy}^2 s_x^2}{s_x^4 s_y^2} = \frac{s_{xy}^2}{s_x^2 s_y^2} = \left(\frac{s_{xy}}{s_x s_y} \right)^2 = r^2,$$

gdje je r Pearsonov koeficijent korelacije koji ukazuje na jakost linearne veze.