

IV.3. Test o lokacijskom pomaku (Mann-Whitney-Wilcoxonov test - MWW)

Zadatak 1. U jednoj kliničkoj studiji šest ispitanika s dijagnozom dijabetesa podijeljeno je na slučajan način u dvije skupine od po tri ispitanika: skupinu A i skupinu B. Skupina A primala je novu terapiju za dijabetes, čija se učinkovitost željela provjeriti. Skupina B primala je standardnu inzulinsku terapiju. Nakon određenog vremena izmjerena je jutarnja koncentracija glukoze u krvi za ispitanike iz obje skupine. Rezultati mjerenja za ispitanike iz skupine A su

$$x_1 = 6.8, x_2 = 7.2, x_3 = 7.4,$$

a za ispitanike iz skupine B

$$y_1 = 8.6, y_2 = 8.9, y_3 = 7.3.$$

Možemo li na razini značajnosti tvrditi da je nova terapija uspješnija od standardne inzulinske terapije?

```
##### Zadatak 1.
#Jutarnju koncentraciju glukoze u krvi dijabetičara koji primaju novu i
#standardnu terapiju modeliramo
#neprekidnim distribucijama, a uzorci su nezavisni.
# F_X – funkcija distribucije koncentracije glukoze u krvi dijabetičara
# koji primaju novu terapiju
# F_Y – funkcija distribucije koncentraciju glukoze u krvi dijabetičara
# koji primaju standardnu terapiju
#Uočimo da su uzorci jako mali i nikako ne bi mogli primijeniti t-test da
#potvrdimo uspješnost nove terapije.
#Zato hipoteze postavljamo za MWW test.
#Uspješnije je manja razina glukoze, zato želimo potvrditi hipotezu da je X
#manje od Y, odnosno da je pomak X-a
#u odnosu na Y negativan.
#Hipoteze:
# H0: F_X(x)=F_Y(x), za sve x \in R
# H1: za delta<0, F_X(x)=F_Y(x-delta), za sve x \in R
#odnosno:
# H0: X =d Y (nema razlike u terapijama)
# H1: za neki delta<0 X =d Y + delta (nova terapija je uspješnija)
#Koristimo MWW test
x <- c(6.8, 7.2, 7.4)
y <- c(8.6, 8.9, 7.3)
wilcox.test(x, y, alternative="less")
#p = 0.1 – na razini značajnosti 0.05 ne odbacujemo H0,
# tj. ne možemo tvrditi da je nova terapija za dijabetes uspješnija od
#standardne inzulinske terapije.
#Ako opcija exact u wilcox.test nije specificirana, izračunava se egzaktna
#p-vrijednost ako su veličine
```

```
#uzoraka manje od 50, inače se koristi normalna aproksimacija test-
  statistike i izračunava se p-vrijednost
#korištenjem te aproksimacije.
#wilcox.test koristi definiciju test-statistike kao u Mann-Whitney U testu,
  odnosno od sume rangova
#oduzima se najmanja moguća suma rangova (ovdje 7 - 6 = 1). Kako je test-
  statistika MWU testa linearna
#transformacija test-statistike MWU testa, p-vrijednosti su jednake.
```

Zadatak 2. U tablici podataka `fitness.csv` nalaze se rezultati testiranja tjelesne kondicije (fitness skor) za uzorak ljudi koji vježbaju kod kuće (varijabla `mjesto` jednaka 0) i uzorak ljudi koji vježbaju u fitness centru (varijabla `mjesto` jednaka 1). Možete li na razini značajnosti 0.05 tvrditi da ljudi koji vježbaju u teretani postižu više vrijednosti fitness skora od ljudi koji vježbaju kod kuće?

```
#### Zadatak 2.
#Fitness skor ljudi koji vježbaju kod kuće i ljudi koji vježbaju u teretani
  modeliramo
# neprekidnim distribucijama, a uzorci su nezavisni.
# F_X - funkcija distribucije fitness skora ljudi koji vježbaju kod kuće
# F_Y - funkcija distribucije fitness skora ljudi koji vježbaju u teretani
#Želimo testirati hipotezu da je X manje od Y, odnosno da je pomak X-a
# u odnosu na Y negativan.
#Hipoteze:
# H0: F_X(x)=F_Y(x), za sve x \in R
# H1: za delta<0, F_X(x)=F_Y(x-delta), za sve x \in R
#odnosno:
# H0: X =d Y (distribucija skora je jednaka)
# H1: za neki delta<0 X =d Y + delta (ljudi koji vježbaju kod kuće
  imaju niži skor od ljudi koji vježbaju u teretani)
#Koristimo MWU test
fitness <- read.csv2("fitness.csv")
str(fitness)
attach(fitness)
x <- skor[mjesto==0]
y <- skor[mjesto==1]
wilcox.test(x, y, alternative = "less")
#Zbog postojanja jednakih podataka u ovim uzorcima (ties - jednaki u
  spojenim uzorcima) nije moguće izračunati egzaktnu p-vrijednost
#p=0.7438 - na razini značajnosti 0.05 ne odbacujemo H0,
# tj. ne možemo tvrditi da ljudi koji vježbaju kod kuće postižu slabije
  rezultate od ljudi koji vježbaju u teretani.
#Uočimo da je jedan uzorak mali i izraženo nejednake veličine, stoga je MWU
  bolji izbor od t-testa.
```

Zadatak 3. Na osnovu podataka iz tablice `turizam.csv` možete li na razini značajnosti 0.05 tvrditi da su sedmodnevni aranžmani za dvije osobe na otocima skuplji od istih takvih aranžmana na obali?

```
##### Zadatak 3.
#Cijene takvih turističkih aranžmana na obali i na otocima modeliramo
  neprekidnim distribucijama, a uzorci su nezavisni.
# F_X – funkcija distribucije cijene takvog turističkog aranžmana na
  otocima
# F_Y – funkcija distribucije cijene takvog turističkog aranžmana na obali
##Želimo testirati hipotezu da je X veće od Y, odnosno da je pomak X-a
# u odnosu na Y pozitivan.
#Hipoteze:
# H0:  $F_X(x)=F_Y(x)$ , za sve  $x \in \mathbb{R}$ 
# H1: za  $\delta > 0$ ,  $F_X(x)=F_Y(x-\delta)$ , za sve  $x \in \mathbb{R}$ 
#odnosno:
# H0:  $X \stackrel{d}{=} Y$  (distribucija cijena je jednaka)
# H1: za neki  $\delta > 0$   $X \stackrel{d}{=} Y + \delta$  (cijene na otocima su veće nego na
  obali)
#Koristimo MW test
turizam <- read.csv2("turizam.csv")
str(turizam)
attach(turizam)
wilcox.test(otoci, obala, alternative="greater")
#  $p < 0.05$  – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo H1,
# tj. možemo tvrditi da su cijene takvih turističkih aranžmana na otocima
  više od onih na obali.
#Zbog postojanja jednakih podataka nije moguće izračunati egzaktnu p-
  vrijednost
#Ne bi bilo pogrešno testirati i hipotezu o očekivanju u ovoj situaciji
  koristeći t-test:
t.test(otoci, obala, alternative="greater")
#Zaključak je da su cijene na otocima veće.
```

Zadatak 4. Dvije skupine pacijenata oboljelih od raka pluća liječene su dvjema metodama liječenja, A i B. U tablici *Censored* iz paketa *BSDA* nalaze se vremena doživljenja u danima za promatrane pacijente. Možemo li na razini značajnosti 0.05 tvrditi da je metoda liječenja A uspješnija?

```
##### Zadatak 4.
#Vremena doživljenja dolaze iz neprekidnih distribucija, a uzorci su
  nezavisni (različiti pacijenti).
# X – vrijeme doživljenja za pacijeta na terapiji A
# Y – vrijeme doživljenja za pacijeta na terapiji B
#Hipoteze:
# H0:  $X \stackrel{d}{=} Y$  (distribucija vremena doživljenja
  su jednaka)
# H1: za neki  $\delta > 0$   $X \stackrel{d}{=} Y + \delta$  (metoda A je uspješnije – veće
  vrijeme doživljenja)
library("BSDA")
str(Censored)
attach(Censored)
x <- survival[treatment == "A"]
```

```
y <- survival[treatment == "B"]
boxplot(x, y)
plot(density(x), col = "blue")
lines(density(y), col = "red")
#Uočimo da su obje distribucije značajno asimetrične. U takvim situacijama
  prikladnije je
# pomak distribucije testirati MMW testom nego testom o očekivanju.
wilcox.test(x, y, alternative="greater")
#p=0.0005437 – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo H1,
# možemo tvrditi da je metoda A uspješnija.
#Kako su uzorci veći od 50, koristi se normalna aproksimacija MMW test
  statistike.
#Općenito, egzaktna verzija može se dobiti s:
wilcox.test(x, y, alternative="greater", exact=T)
#Zbog postojanja jednakih ovdje se ne može primijeniti što rezultira
  warningom.
```

IV.4. Testovi o distribuciji općenito za nezavisne slučajne uzorke

1. χ^2 -test o homogenosti

Zadatak 5. Za obradu određenog nastavnog gradiva primjenjene su dvije različite nastavne metode. Metoda 1 primijenjena je u skupini od 100 učenika, a metoda 2 u skupini od 200 učenika. Da bi se utvrdio učinak, svi su učenici ispitani i ocijenjeni odgovarajućom ocjenom od 1 do 5.

metoda \ ocjena	1	2	3	4	5	Σ
1	14	26	34	16	10	100
2	18	36	58	56	32	200
Σ	32	62	92	72	42	300

Postoji li na razini značajnosti 0.05 razlika u uspješnosti ove dvije metode? Analizirajte očekivane frekvencije u odnosu na opažene frekvencije. Koja metoda daje bolje rezultate?

```
##### Zadatak 5.
#Promatramo obilježje s 5 mogućih vrijednosti u dvije populacije.
#Hipoteze:
# H0: distribucije ocjena kod metode A i metode B su jednake
# H1: distribucije ocjena kod metode A i metode B nisu jednake
metode <- matrix(c(14, 26, 34, 16, 10, 18, 36, 58, 56, 32), 2, 5, byrow =
  TRUE)
colnames(metode) <- c("1", "2", "3", "4", "5")
rownames(metode) <- c("1", "2")
metode
chisq.test(metode)
#p = 0.04241 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
  H1,
# možemo tvrditi da ove dvije metode rezultiraju različitim distribucijama
  ocjena.

chisq.test(metode)$expected      # tablica očekivanih (teorijskih)
  frekvencija u uvjetima istinitosti H0
chisq.test(metode)$observed     # tablica opaženih frekvencija (tablica
  koju smo unijeli)
#Za usporedbu zaokružimo te brojeve
round(chisq.test(metode)$expected)
chisq.test(metode)$observed
#Možemo promatrati i razlike
chisq.test(metode)$observed-round(chisq.test(metode)$expected)
#Više je boljih ocjena kod druge metode – daje naslutiti da je ona bolja.
#Slično možemo uočiti i ako pogledamo uvjetne relativne frekvencije:
prop.table(metode, 1)
```

Zadatak 6. Jedno istraživanje želi ispitati utjecaj stresa na altruistično ponašanje. Formirane su dvije grupe od po 100 ispitanika. Obje grupe pisale su test osobnosti, no u različitim uvjetima - prva grupa u tišini, a druga grupa u prisutnosti uznemirujuće buke. Odmah po izlasku s testiranja svaki je ispitanik bio suočen sa starijim čovjekom kojemu je trebala pomoć oko prenošenja stvari u automobil. Od ispitanika koji su test pisali u tišini 60 ih je pružilo pomoć starijem čovjeku, dok je od ispitanika koji su test pisali u uvjetima buke starijem čovjeku pomoglo 45 njih. Možemo li na razini značajnosti 0.05 tvrditi da se proporcije ispitanika koji su starijem čovjeku pružili pomoć razlikuju s obzirom na uvjete u kojima su pisali test?

```
##### Zadatak 6.
#Dva ishoda: 1 – pomogao, 0 – nije pomogao.
#Dvije populacije:
# 1. u tišini – distribucija ( 0      1      )
#                          1-theta1  theta1
# 2. buka – distribucija   ( 0      1      )
#                          1-theta2  theta2
#Želimo testirati jesu li te dvije distribucije jednake.
#U ovom slučaju jednakost distribucija se svodi na jednakost proporcija pa
#bi problem mogli
# postaviti i kao hipoteze o proporciji za nezavisne uzorke.
# H0: theta1 = theta2
# H1: theta1 != theta2
prop.test(c(60, 45), c(100, 100))
#p = 0.04744 < 0.05 odbacujemo H0, proporcije se razlikuju.
#Ako bi hipoteze postavili u terminima distribucija:
# H0: distribucije su jednake u tišini i u buci
# H1: nisu jednake
#Odgovarajuća tablica frekvencija:
(buka <- matrix(c(40, 60, 55, 45), 2, 2, byrow = TRUE))
chisq.test(buka)
#p = 0.04744 < 0.05 odbacujemo H0, distribucije se razlikuju.
#Radi se o ekvivalentnim testovima, tako da je svejedno hoćemo li hipoteze
#postaviti kao
# hipoteze o distribuciji ili o proporciji. Za razliku od chi^2 testa, test
#o proporciji
# možemo iskoristiti samo kada obilježje ima dva ishoda i promatra se u
#dvije populacije.
#Test koristi tzv. Yatesovu korekciju zbog neprekidnosti za 2x2 tablice.
#Očekivane frekvencije:
chisq.test(buka)$expected
#Ukupno je pomoglo 105 ljudi od njih 200, 52.5%. Ako su distribucije
#jednake, onda
#na 100 ljudi očekujemo da će pomoći 52.5 njih.
```

Zadatak 7. Provedeno je istraživanje o rasprostranjenosti alkoholizma za četiri kategorije zanimanja (300 službenika, 250 nastavnika, 300 menadžera i 350 trgovaca). Rezultati istraživanja dani su u sljedećoj tablici:

	alkoholičari	nealkoholičari	Σ
službenici	32	268	300
nastavnici	51	199	250
menadžeri	67	233	300
trgovci	83	267	350
Σ	233	967	1200

Možemo li na razini značajnosti 0.05 tvrditi da je alkoholizam zastupljeniji u nekoj od promatranih kategorija zanimanja?

```
##### Zadatak 7.
#Radi se o obilježju sa dva moguća ishoda promatranom u četiri populacije
#Hipoteze:
# H0: alkoholizam je jednako zastupljen u svim promatranim zanimanjima
# H1: alkoholizam nije jednako zastupljen u svim promatranim zanimanjima
(alkohol <- matrix(c(32, 268, 51, 199, 67, 233, 83, 267), 4, 2, byrow = T))
chisq.test(alkohol)
#p = 0.0001277 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i
    prihvaćamo H1,
# možemo tvrditi da alkoholizam nije jednako zastupljen u svim promatranim
    zanimanjima.
```

2. Kolmogorov-Smirnovljev test za dva nezavisna slučajna uzorka

Zadatak 8. Varijable `placa_poslije` i `placa_konkurencija` iz tablice `djelatnici.csv` sadrže iznose godišnjih plaća u eurima za uzorak zaposlenika jednog poduzeća i za uzorak zaposlenika konkurentskog poduzeća, redom. Ako su uzorci nezavisni, utvrdite razlikuju li se distribucije plaća u tim poduzećima na razini značajnosti 0.05?

```
##### Zadatak 8.
#Iznose plaća u tim poduzećima modeliramo neprekidnim distribucijama
# F_X – funkcija distribucije iznosa godišnje plaće u prvom poduzeću
# F_Y – funkcija distribucije iznosa godišnje plaće u konkurentskom
    poduzeću
#Uzorci su nezavisni.
#Hipoteze:
# H0: F_X(x)=F_Y(x), za sve x \in R
# H1: F_X(x) != F_Y(x), za neki x \in R
#Grafovi empirijskih funkcija distribucije
djelatnici <- read.csv2("djelatnici.csv")
```

```

str(djelatnici)
attach(djelatnici)
#Koristimo Kolmogorov–Smirnovljev test za dva nezavisna slučajna uzorka
ks.test(placa_poslije, placa_konkurencija) #default vrijednost za
      alternative je "two.sided"
#p=1.264e-12 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo
      H1,
# možemo tvrditi da su visine godišnjih plaća u ta dva poduzeća različito
      distribuirane.
#Empirijske funkcije distribucije možemo usporediti grafički:
plot(ecdf(placa_poslije), col = "blue")
plot(ecdf(placa_konkurencija), add = T, col = "red")
#Uočimo da distribucije imaju različite oblike, MWW test ovdje stoga ne bi
      bio prikladan
# jer zahtijeva da se distribucije razlikuju samo za pomak.

```

Zadatak 9. U tablici `turizam.csv` nalaze se podaci o cijenama sedmodnevnih turističkih aranžmana za dvije osobe u nekim ljetovalištima na obali (varijabla `obala`) i nekim ljetovalištima na otocima (varijabla `otoci`) u Hrvatskoj.

- Razlikuju li se distribucije cijena turističkih aranžmana te vrste na obali i na otocima na razini značajnosti 0.05?
- Testirajte iste hipoteze MWW testom. Je li korektno primijeniti taj test?
- Ima li smisla cijene takvih aranžmana na obali i na otocima modelirati normalnim distribucijama? Ako ima, testirajte hipoteze o razlici očekivanja.

```

#### Zadatak 9.
#(a)
#Cijene takvih turističkih aranžmana na obali i na otocima modeliramo
      neprekidnim distribucijama.
# F_X – funkcija distribucije cijena na obali
# F_Y – funkcija distribucije cijena na otocima
#Uzorci su nezavisni.
#Hipoteze:
# H0: F_X(x)=F_Y(x), za sve x \in R
# H1: F_X(x) != F_Y(x), za neki x \in R
turizam <- read.csv2("turizam.csv")
str(turizam)
attach(turizam)
ks.test(obala, otoci)
#p = 3.934e-13 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i
      prihvaćamo H1,
# možemo tvrditi da se cijene razlikuju.
#Warning upozorava na to da u promatranim uzorcima ima jednakih cijena, pa
      se p-vrijednost KS testa određuje
# korištenjem asimptotske distribucije KS test-statistike.

```

```

#(b)
#Dodatna pretpostavka u MWV testu jest da se distribucije razlikuju samo za
lokacijski pomak (istog su "oblika").
plot(ecdf(obala), col = "blue", xlim = c(min(c(obala, otoci)), max(c(obala,
otoci))))
plot(ecdf(otoci), add = T, col = "red")
#Na osnovu grafova, nije pogrešno to i pretpostaviti.
wilcox.test(obala, otoci)
#p = 2.54e-12 < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i
prihvaćamo H1,
# možemo tvrditi da se cijene razlikuju, odnosno da postoji lokacijski
pomak različit od 0.

#(c)
#Obala:
plot(density(obala))
shapiro.test(obala)
#p = 0.1841 > 0.05 – ne odbacujemo nul-hipotezu, nema razloga sumnjati u
normalnu distribuiranost
#Otoci:
plot(density(otoci))
shapiro.test(otoci)
#p = 0.1015 > 0.05 – ne odbacujemo nul-hipotezu, nema razloga sumnjati u
normalnu distribuiranost

#Hipoteze o očekivanju:
# H0: mu1 = mu2
# H1: mu1 != mu2
t.test(obala, otoci)
#p < 0.05 – na razini značajnosti 0.05 odbacujemo H0 i prihvaćamo H1,
# možemo tvrditi da se očekivane cijene razlikuju (pa onda i distribucije).

#Uočimo da smo s tri različita testa testirali vrlo slične hipoteze.

```

Zadatak 10. Na pustoj poljani nalaze se samo dva stabla jabuka - jedno sorte Whitney Crab, a drugo sorte Redwell. Pčele nemaju drugog izbora nego hraniti se iz cvjetova tih dvaju stabala. Pčelar želi provjeriti preferiraju li pčele jednu od ovih sorti jabuka i u tu svrhu stopericom mjeri vrijeme koje pčela provede u blizini stabla jabuke - mjerenje počinje u trenutku u kojem pčela sleti na stablo, a prestaje u trenutku kad se pčela udalji od stabla za više od jednog metra. Rezultati mjerenja nalaze se u tablici **jabuka.csv**. Može li pčelar na razini značajnosti 0.05 tvrditi da pčele preferiraju jednu od dviju promatranih sorti jabuka?

```

#### Zadatak 10.
#Vrijeme koje pčela provede u blizini stabala jabuka ovih dviju sorti
modeliramo neprekidnom distribucijama,
#a uzorci su nezavisni.
# F_X – funkcija distribucije vremena koje pčela provede u blizini stabla
sorte Whitney Crab

```

```
# F_Y – funkcija distribucije vremena koje pčela provede u blizini stabla
# sorte Redwell
#Hipoteze:
# H0:  $F_X(x)=F_Y(x)$ , za sve  $x \in R$ 
# H1:  $F_X(x) \neq F_Y(x)$ , za neki  $x \in R$ 
jabuka <- read.csv2("jabuka.csv")
str(jabuka)
attach(jabuka)
#Koristimo Kolmogorov–Smirnovljev test za dva nezavisna slučajna uzorka
ks.test(wc, rw)
#Warning upozorava na to da u promatranim uzorcima ima jednakih vrijednosti
# , pa se p-vrijednost KS testa određuje
# korištenjem asimptotske distribucije KS test-statistike
#p=0.05156 – na razini značajnosti 0.05 ne odbacujemo H0,
# ne možemo tvrditi da pčele preferiraju jednu od dviju promatranih sorti
# jabuka.
#Grafovi empirijskih funkcija distribucije
plot(ecdf(wc), col = "blue")
plot(ecdf(rw), add = TRUE, col = "red")
```