

IV.3. Test o lokacijskom pomaku (Mann-Whitney-Wilcoxonov test - MWW)

Neka su $\mathbf{X} = (X_1, \dots, X_{n_1})$ i $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$ nezavisni j.s.u. iz neprekidnih distribucija F_X i F_Y slučajnih varijabli X i Y .

U MWW testu pretpostavljamo da F_X i F_Y imaju *isti oblik*, ali se mogu razlikovati za lokacijski pomak, tj. za neki $\delta \in \mathbb{R}$

$$F_X(x) = F_Y(x - \delta), \quad \text{za sve } x \in \mathbb{R}.$$

Uočimo da to znači da za sve $x \in \mathbb{R}$

$$P(X \leq x) = F_X(x) = F_Y(x - \delta) = P(Y \leq x - \delta) = P(Y + \delta \leq x)$$

odnosno

$$X \stackrel{d}{=} Y + \delta \Leftrightarrow X - \delta \stackrel{d}{=} Y.$$

Nul-hipotezu

$$H_0 : F_X(x) = F_Y(x) \text{ za sve } x \in \mathbb{R},$$

možemo u tom slučaju iskazati kao

$$H_0 : \delta = 0.$$

Alternativne hipoteze mogu biti:

- dvostrana hipoteza – postoji lokacijski pomak (posebno, i distribucije se razlikuju)

$$H_1 : \text{postoji } \delta \in \mathbb{R} \text{ takav da je } F_X(x) = F_Y(x - \delta), \quad \text{za sve } x \in \mathbb{R}$$


- jednostrana hipoteza – postoji pozitivan lokacijski pomak ($\delta > 0$) X u odnosu na Y

$$H_1 : \text{postoji } \delta > 0 \text{ takav da je } F_X(x) = F_Y(x - \delta), \quad \text{za sve } x \in \mathbb{R}$$


što možemo jednostavnije zapisati i kao

$$H_1 : X \stackrel{d}{=} Y + \delta \text{ za neki } \delta > 0.$$

Hipotezu shvaćamo kao **X je veći od Y** (u R-u će to biti predstavljeno argumentom *greater*). U terminima funkcija gustoća to bi izgledalo kao na sljedećoj slici:



dok bi u terminima funkcija distribucija to izgledalo ovako:



Primijetimo da je u ovoj situaciji zapravo $F_X(x) \leq F_Y(x)$.


- jednostrana hipoteza – postoji negativan lokacijski pomak ($\delta < 0$) X u odnosu na Y

$$H_1 : \text{postoji } \delta < 0 \text{ takav da je } F_X(x) = F_Y(x - \delta), \text{ za sve } x \in \mathbb{R}$$


što možemo jednostavnije zapisati i kao

$$H_1 : X \stackrel{d}{=} Y + \delta \text{ za neki } \delta < 0.$$

Hipotezu shvaćamo kao **X je manji od Y** (u R-u će to biti predstavljeno argumentom *less*). U terminima funkcija gustoća to bi izgledalo kao na sljedećoj slici:



a u terminima funkcija distribucija ovako:



Uočimo da ako je za neki $\delta \in \mathbb{R}$, $F_X(x) = F_Y(x - \delta)$ za sve $x \in \mathbb{R}$, onda je $X \stackrel{d}{=} Y + \delta$ pa je posebno i

$$EX = EY + \delta \Leftrightarrow \mu_1 - \mu_2 = \delta,$$

za $\mu_1 = EX$ i $\mu_2 = EY$. Osim toga je i medijan od X jednak zbroju medijana od Y i δ .

Stoga iz ovih hipoteza slijede hipoteze o očekivanju ili medijanu. U tom smislu, MWW test je alternativa klasičnom t -testu. Prednost MWW testa je što nema pretpostavke na distribuciju (neparametarski u tom smislu) i egzaktna je pa se može koristiti i za male uzorke. Važan je kad želimo testirati pomak između dva obilježja, a uzorci kojima raspolažemo su mali pa ne možemo računati na centralni granični teorem.

Nećemo detaljno opisivati teoriju koja se krije iza ovog testa, ali pokušat ćemo ilustrirati osnovnu ideju. Neka je $\mathbf{x} = (x_1, \dots, x_{n_1})$ realizacija od $\mathbf{X}$ i $\mathbf{y} = (y_1, \dots, y_{n_2})$ realizacija od $\mathbf{Y}$. Spojimo ta dva niza u jedan niz $\mathbf{z}$ duljine $n_1 + n_2$ i sortiramo ga u rastućem poretku. Ideja testa je da

- ako je H_0 istinita, elementi od $\mathbf{x}$ i $\mathbf{y}$ bi trebali biti dobro *izmiješani* u $\mathbf{z}$,
- ako, primjerice, većina većih elemenata od $\mathbf{z}$ potječe od $\mathbf{y}$, onda sumnjamo da je X *manji* od Y .

Primjerice, ako je $n_1 = n_2 = 3$, onda

- $x_1 \leq y_1 \leq x_2 \leq y_2 \leq x_3 \leq y_3$ ide u prilog H_0 ,
- $x_1 \leq x_2 \leq x_3 \leq y_1 \leq y_2 \leq y_3$ ide u prilog tome da je X *manji* od Y .

Taj efekt možemo kvantificirati tako da promatramo **rangove** – redne brojeve podataka u sortiranom nizu. Pokazuje se da suma rangova u $\mathbf{z}$ jednog niza ($\mathbf{x}$ ili $\mathbf{y}$) u uvjetima H_0 ima egzaktnu distribuciju koja ovisi samo o n_1 i n_2 . Za velike uzorke distribuciju nije jednostavno egzaktno izračunati pa se koristi asimptotska verzija testa (u R-u za više od 50 podataka.)

Test je još poznat i kao Wilcoxonov test sume rangova ili Mann-Whitney U test.

IV.4. Testovi o distribuciji općenito za nezavisne slučajne uzorke

Želimo testirati dolaze li dva (ili više) uzoraka iz iste distribucije. Nulta hipoteza bit će kao kod MWW testa. MWW test može biti neprikladan zbog pretpostavke da su distribucije neprekidne ili zbog pretpostavke da se distribucije razlikuju samo za lokacijski pomak što je specijalni slučaj razlike među distribucijama.

1. χ^2 -test o homogenosti

χ^2 -testom o homogenosti možemo testirati je li distribucija nekog diskretnog obilježja jednaka u $m \geq 2$ populacija (**homogenost**). Iz svake populacije dolazi jedan uzorak

- populacija 1 – $(Y_1^{(1)}, \dots, Y_{n_1}^{(1)})$ j.s.u. iz $\begin{pmatrix} y_1 & \dots & y_n \\ p_1^{(1)} & \dots & p_n^{(1)} \end{pmatrix}$,
- populacija 2 – $(Y_1^{(2)}, \dots, Y_{n_2}^{(2)})$ j.s.u. iz $\begin{pmatrix} y_1 & \dots & y_n \\ p_1^{(2)} & \dots & p_n^{(2)} \end{pmatrix}$,
- $\vdots$
- populacija m – $(Y_1^{(m)}, \dots, Y_{n_m}^{(m)})$ j.s.u. iz $\begin{pmatrix} y_1 & \dots & y_n \\ p_1^{(m)} & \dots & p_n^{(m)} \end{pmatrix}$.

Svi uzorci su međusobno nezavisni. Hipoteze su

$$H_0 : p_j^{(1)} = p_j^{(2)} = \dots = p_j^{(m)}, \quad j = 1, \dots, n,$$

$$H_1 : \text{ne } H_0.$$

Realizacije slučajnih uzoraka u ovakvim problemima obično zapisujemo u obliku tablice frekvencija na sljedeći način

	y_1	y_2	$\dots$	y_n	
1	f_{11}	f_{12}	$\dots$	f_{1n}	n_1
2	f_{21}	f_{22}	$\dots$	f_{2n}	n_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
m	f_{m1}	f_{m2}	$\dots$	f_{mn}	n_m
	f_1	f_2	$\dots$	f_n	N

gdje je

- f_{ij} frekvencija y_j u i -toj populaciji
- $f_j = \sum_{i=1}^m f_{ij}$ je frekvencija y_j u realizacijama svih uzoraka zajedno
- $N = \sum_{i=1}^m n_i$ je veličina svih uzoraka zajedno.

Ako je H_0 istinita, onda bi $p_j^{(1)} = p_j^{(2)} = \dots = p_j^{(m)}$ mogli procijeniti na osnovu svih podataka s

$$\hat{p}_j = \frac{f_j}{N}, \quad j = 1, \dots, n.$$

Stoga bi očekivana frekvencija y_j u i -toj populaciji bila

$$\hat{p}_j n_i, \quad i = 1, \dots, m, \quad j = 1, \dots, n.$$

Test statistiku definiramo kao

$$D_{m,n} = \sum_{i=1}^m \sum_{j=1}^n \frac{(f_{ij} - \hat{p}_j n_i)^2}{\hat{p}_j n_i}.$$

Uočimo da test statistika ima sličnu strukturu kao kod χ^2 -testa na jednom uzorku, tj. oblika je (opažene – očekivane frekvencije)²/očekivane frekvencije. U uvjetima H_0 , $D_{m,n}$ asimptotski ima $\chi^2((m-1)(n-1))$ distribuciju (pokaže se sličnim argumentima kao kod χ^2 -testa na jednom uzorku).

Veće vrijednosti od $D_{m,n}$ idu u prilog H_1 stoga je kritično područje

$$C = [h_\alpha, \infty), \quad h_\alpha = Q_{\chi^2((m-1)(n-1))}(1 - \alpha)$$

i p -vrijednost $p = P(\chi^2((m-1)(n-1)) \geq \hat{d}_{m,n})$ za realizaciju test statistike $\hat{d}_{m,n}$. Kao i kod testa na jednom uzorku, za primjenu bi očekivane frekvencije trebale biti barem 5.

2. Kolmogorov-Smirnovljev test za dva nezavisna slučajna uzorka

Neka su $\mathbf{X} = (X_1, \dots, X_{n_1})$ i $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$ nezavisni j.s.u. iz neprekidnih distribucija F_X i F_Y slučajnih varijabli X i Y . Hipoteze su

$$H_0 : F_X(x) = F_Y(x) \text{ za sve } x \in \mathbb{R},$$

$$H_1 : \text{postoji } x \in \mathbb{R} \text{ takav da je } F_X(x) \neq F_Y(x).$$

Test statistika se temelji na empirijskim funkcijama distribucije

$$\hat{F}_X(x) = \frac{1}{n_1} \sum_{i=1}^{n_1} I_{\{X_i \leq x\}}$$

$$\hat{F}_Y(x) = \frac{1}{n_2} \sum_{i=1}^{n_2} I_{\{Y_i \leq x\}}$$

i zadana je s

$$D_{n_1, n_2} = \sup_{x \in \mathbb{R}} |\hat{F}_X(x) - \hat{F}_Y(x)|.$$

Pokazuje se da distribucije od D_{n_1, n_2} ne ovisi o F_X i F_Y već samo o veličinama uzoraka. Test se provodi slično kao kod testa na jednom uzorku (u R-u egzaktna p -vrijednost

računa se do uzoraka veličine 100 i bez jednakih elemenata u uzorcima). Za razliku od MWW testa i t -testa, Kolmogorov-Smirnovljevim testom možemo uspoređivati proizvoljne distribucije. Osim toga, test je egzaktni.

Moguće je promatrati i jednostrane alternativne hipoteze, primjerice $H_1 : F_X(x) < F_Y(x)$ za neki $x \in \mathbb{R}$. Međutim, moguće je da je istovremeno i $F_X(x) > F_Y(x)$ za neki $x \in \mathbb{R}$ što onda otežava interpretaciju hipoteze kao primjerice tvrdnje „ X je veće od Y “. Osim toga, u R-u nema egzaktnih p -vrijednosti za jednostrane alternativne hipoteze. Iz tih razloga nećemo promatrati takve oblike H_1 .