

IV. Statističko zaključivanje temeljeno na dva uzorka

U okviru ovog poglavlja proučavat ćemo dva slučajna uzorka, razlike u njihovim distribucijama i međusobnu zavisnost. Razlikujemo dvije tipične situacije.

Nezavisni slučajni uzorci Pod nezavisnim uzorcima smatramo

- $\mathbf{X} = (X_1, \dots, X_{n_1})$ j.s.u. iz neke distribucije,
- $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$ j.s.u. iz neke distribucije,
- $\mathbf{X}$ i $\mathbf{Y}$ su nezavisni.

Dakle, sve $X_i, i = 1, \dots, n_1$, i $Y_j, j = 1, \dots, n_2$, su međusobno nezavisne, $X_1, \dots, X_{n_1}$ su jednako distribuirane, $Y_1, \dots, Y_{n_2}$ su jednako distribuirane, ali ne mora biti $X_1 \stackrel{d}{=} Y_1$. Prvo ćemo se baviti pitanjima jednakosti distribucija iz koje dolaze uzorci.

Vezani slučajni uzorci Pod vezanim (zavisnim) slučajni uzorcima smatramo dva slučajna uzorka $\mathbf{X}^{(1)} = (X_1^{(1)}, \dots, X_n^{(1)})$ i $\mathbf{X}^{(2)} = (X_1^{(2)}, \dots, X_n^{(2)})$ takva da je

$$\left((X_1^{(1)}, X_1^{(2)}), \dots, (X_n^{(1)}, X_n^{(2)}) \right)$$

dvodimenzionalan j.s.u., odnosno $(X_1^{(1)}, X_1^{(2)}), \dots, (X_n^{(1)}, X_n^{(2)})$ su nezavisni i jednako distribuirani slučajni vektori. Posebno, to znači i da je $(X_1^{(1)}, \dots, X_n^{(1)})$ j.s.u. iz neke distribucije i $(X_1^{(2)}, \dots, X_n^{(2)})$ je j.s.u. iz neke distribucije, ali $X_i^{(1)}$ i $X_i^{(2)}$ ne moraju biti nezavisne za $i = 1, \dots, n$. Uočimo da su u ovoj situaciji uzorci uvijek iste veličine jer dolaze u parovima. Ovakvi uzorci pojavljuju se kada promatramo neko obilježje na istim jedinkama u različitim trenucima (npr. prije ili poslije nekog tretmana) ili pod različitim uvjetima. U tom smislu kažemo da se radi o vezanim ili uparenim uzorcima (eng. paired samples).

Primjerice, ako mjerimo masu muškaraca i žena u nekoj populaciji, onda se radi o nezavisnim uzorcima. Ako mjerimo masu istih osoba prije treninga i poslije treninga, onda se radi o vezanim uzorcima.

IV.1. Testovi o očekivanju za nezavisne slučajne uzorke

Sadržaj

1. Normalno distribuirane populacije, poznate varijance (<i>z</i> -test)	3
2. Normalno distribuirane populacije, nepoznate varijance (Welchov <i>t</i> -test)	3
3. Veliki uzorci	4

Na osnovu dva nezavisna j.s.u. $\mathbf{X} = (X_1, \dots, X_{n_1})$ i $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$, $E X_1 = \mu_1$, $E Y_1 = \mu_2$, želimo testirati

$$H_0 : \mu_1 = \mu_2.$$

Treba primijetiti da u odnosu na testove na jednom uzorku, ovdje su i μ_1 i μ_2 nepoznati. Kao i prije, odabir testa ovisi o pretpostavkama koje uzorci zadovoljavaju.

1. Normalno distribuirane populacije, poznate varijance (*z*-test)

Neka su $\mathbf{X} = (X_1, \dots, X_{n_1})$ j.s.u. iz $\mathcal{N}(\mu_1, \sigma_1^2)$ i $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$ j.s.u. iz $\mathcal{N}(\mu_2, \sigma_2^2)$ nezavisni i σ_1^2 i σ_2^2 poznati. Test statistika koju koristimo je

$$T(\mathbf{X}, \mathbf{Y}) = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}.$$

Uočimo da je $\bar{X}_{n_1} \sim \mathcal{N}\left(\mu_1, \frac{\sigma_1^2}{n_1}\right)$ i $\bar{Y}_{n_2} \sim \mathcal{N}\left(\mu_2, \frac{\sigma_2^2}{n_2}\right)$ te da su nezavisne, stoga je $\bar{X}_{n_1} - \bar{Y}_{n_2} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)$.

U uvjetima kad vrijedi H_0 je $\mu_1 - \mu_2 = 0$ pa je $T(\mathbf{X}, \mathbf{Y}) \sim \mathcal{N}(0, 1)$. Kritično područje i *p*-vrijednost određuju se kao kod *z*-testa na jednom uzorku. Kao i kod testa na jednom uzorku, potpuno je nerealna pretpostavka da su varijance poznate.

2. Normalno distribuirane populacije, nepoznate varijance (Welchov *t*-test)

Neka su $\mathbf{X} = (X_1, \dots, X_{n_1})$ j.s.u. iz $\mathcal{N}(\mu_1, \sigma_1^2)$ i $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$ j.s.u. iz $\mathcal{N}(\mu_2, \sigma_2^2)$ nezavisni i σ_1^2 i σ_2^2 nepoznati. Test statistika

$$T(\mathbf{X}, \mathbf{Y}) = \frac{\bar{X}_{n_1} - \bar{Y}_{n_2}}{\sqrt{\frac{S_{n_1}^2}{n_1} + \frac{S_{n_2}^2}{n_2}}}.$$

u uvjetima H_0 ima Studentovu distribucije $\mathcal{T}_\nu$ gdje je ν aproksimativna vrijednost broja stupnjeva slobode koja se dobije tzv. Welch–Satterthwaitovom formulom

$$\nu = \frac{\left(\frac{s_{n_1}^2}{n_1} + \frac{s_{n_2}^2}{n_2}\right)^2}{\frac{s_{n_1}^4}{n_1^2(n_1-1)} + \frac{s_{n_2}^4}{n_2^2(n_2-1)}}.$$

Kritično područje i p -vrijednosti određuju se kao kod t -testa na jednom uzorku.

Klasični t -test na dva uzorku pretpostavlja da su varijance σ_1^2 i σ_2^2 nepoznate ali jednake $\sigma_1^2 = \sigma_2^2$ i u nazivniku test statistike nalazi se izraz

$$s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}},$$

gdje

$$s_p^2 = \frac{(n_1 - 1)s_{n_1}^2 + (n_2 - 1)s_{n_2}^2}{n_1 + n_2 - 2}$$

predstavlja *zajedničku varijancu*. U tom slučaju, test statistika ima $\mathcal{T}_{n_1+n_2-2}$ distribuciju. Ipak, pretpostavku o jednakosti varijanci treba provjeriti što unosi dodatnu nesigurnost. Preporuka je stoga koristiti izravno Welchovu verziju t -testa.

3. Veliki uzorci

Za velike uzorke (barem $n_1 > 30$ i $n_2 > 30$) možemo koristiti Welchov t -test. Kao i inače, treba biti oprezan sa zaključcima.

IV.2. Test o proporciji za nezavisne slučajne uzorke

Neka su $\mathbf{X} = (X_1, \dots, X_{n_1})$ j.s.u. iz Bernoullijeve distribucije

$$\begin{pmatrix} 0 & 1 \\ 1 - \theta_1 & \theta_1 \end{pmatrix}$$

i $\mathbf{Y} = (Y_1, \dots, Y_{n_2})$ j.s.u. iz Bernoullijeve distribucije

$$\begin{pmatrix} 0 & 1 \\ 1 - \theta_2 & \theta_2 \end{pmatrix}$$

nezavisni. Ako želimo testirati

$$H_0 : \theta_1 = \theta_2,$$

test statistika je

$$T(\mathbf{X}, \mathbf{Y}) = \frac{(\bar{X}_{n_1} - \bar{Y}_{n_2})^2}{\frac{n_1 \bar{X}_{n_1} + n_2 \bar{Y}_{n_2}}{n_1 + n_2} \left(1 - \frac{n_1 \bar{X}_{n_1} + n_2 \bar{Y}_{n_2}}{n_1 + n_2}\right) \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}.$$

Uočimo da izraz

$$\frac{n_1 \bar{X}_{n_1} + n_2 \bar{Y}_{n_2}}{n_1 + n_2}$$

predstavlja relativnu frekvenciju uspjeha u oba uzorka zajedno. Ako vrijedi H_0 , onda $\sqrt{T(\mathbf{X}, \mathbf{Y})}$ asimptotski ima $\mathcal{N}(0, 1)$ distribuciju pa $T(\mathbf{X}, \mathbf{Y})$ asimptotski ima χ_1^2 distribuciju (vidi Propozicija 2 Predavanje II.1.).

Test se može provoditi kao z -test ili kao χ^2 -test na osnovu čega se određuje kritično područje odnosno p -vrijednost. Zaključak je ekvivalentan. U R-u test provodimo funkcijom `prop.test()` koja koristi gore definiranu test statistiku. Ta procedura koristi i korekciju zbog neprekidnosti koja umanjuje problem što je uzorak iz diskretne distribucije a test statistika asimptotski ima neprekidnu distribuciju. Treba zapamtiti da je test asimptotski te stoga zahtijeva velike uzorke.